10

SESIÓN 10

Integración de datos para IA generativa: vectores, recuperación y el patrón RAG

Semana 10 · 3 horas (180 min) · Se publica el Taller 2 · Entrega 1 del Proyecto

10 Objetivos y preparación

OBJETIVOS DE APRENDIZAJE

1. Explicar los embeddings y la búsqueda por similitud como capa de integración de datos no estructurados
2. Diseñar un pipeline de recuperación completo y justificar sus decisiones de arquitectura
3. Reconocer cuándo el grafo de conocimiento complementa o reemplaza la búsqueda vectorial

LECTURAS PREVIAS (≤ 85 MIN)

- Huyen, C. AI Engineering — capítulo de RAG y gestión de contexto
- Nota del curso: el patrón RAG leído con el vocabulario de Hohpe & Woolf
- Opcional: survey de RAG agéntico; introducción a GraphRAG

ACTIVIDAD DETONANTE (LMS)

Un operador pregunta por un límite de presión y el modelo responde con una cifra plausible pero equivocada. ¿Por qué un modelo sin recuperación es peligroso aquí, y qué debería devolver además de la respuesta?

10

Agenda de la sesión (180 min)

Bloque	Min	Actividad	Objetivo
0	5	Apertura y encuadre	—
1	35	El dato no estructurado como problema de integración	1
2	45	Anatomía del pipeline de recuperación: las cuatro etapas	2
R	**15**	**Receso**	—
3	30	Límites del vector, grafos de conocimiento y el patrón de integración	3
4	40	Práctica en papel: especificar la ingesta y decidir la topología	2 y 3
5	10	Lanzamiento del Taller 2 y cierre	—

La práctica se resuelve con lápiz y papel. La implementación se traslada al Taller 2, que se publica al cierre de esta sesión.

10

El recorrido de la sesión

De por qué el dato no estructurado nunca entró a la arquitectura, a cómo se integra con disciplina

1

El dato no estructurado

Embeddings, búsqueda por similitud y el almacén vectorial como sistema a integrar

2

El pipeline de recuperación

Ingesta, recuperación, generación controlada y evaluación

3

Límites y patrón

Dónde falla el vector, qué aporta el grafo, y el patrón EIP que hay detrás

4

Aplicar

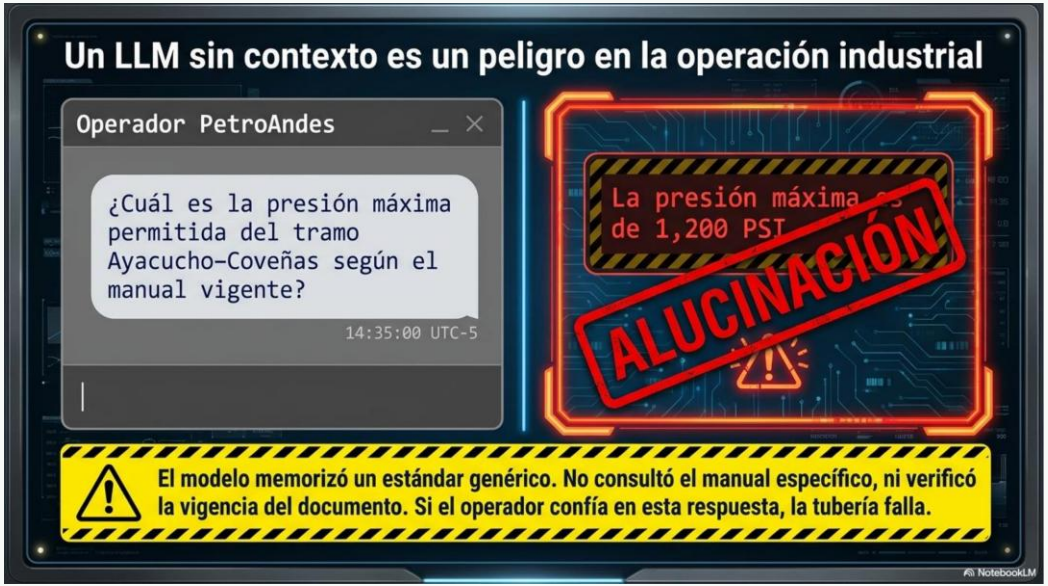
Práctica en papel y lanzamiento del Taller 2

La tesis de la sesión: no estamos aprendiendo IA. Estamos integrando una fuente de datos que la arquitectura empresarial venía ignorando, y le exigimos el mismo rigor que a cualquier otra.

10

El riesgo: responder sin consultar la fuente

Bloque 1 · por qué este es un problema de arquitectura y no de redacción de prompts



QUÉ FALLÓ, EN TÉRMINOS DE INTEGRACIÓN

- El sistema respondió desde conocimiento memorizado, no desde la fuente autorizada
- No hubo trazabilidad: la respuesta no cita documento, versión ni sección
- No se verificó la vigencia del documento, que es un dato de gobierno
- El consumidor no pudo distinguir una respuesta fundamentada de una inventada

Toda la sesión es una respuesta a esta lámina: cómo se construye una integración que no puede fallar así.

10

El dato que la arquitectura venía ignorando

Bloque 1 · manuales, procedimientos, contratos, correos y actas: la mayor parte del conocimiento de una organización

LO QUE YA SABEMOS INTEGRAR

Dato estructurado

- Esquema declarado y contrato versionado
- Mecanismo elegido: consolidar, federar o propagar
- Dueño identificable y latencia comprometida
- Calidad medible: completitud, frescura, unicidad

LO QUE QUEDABA AFUERA

Dato no estructurado

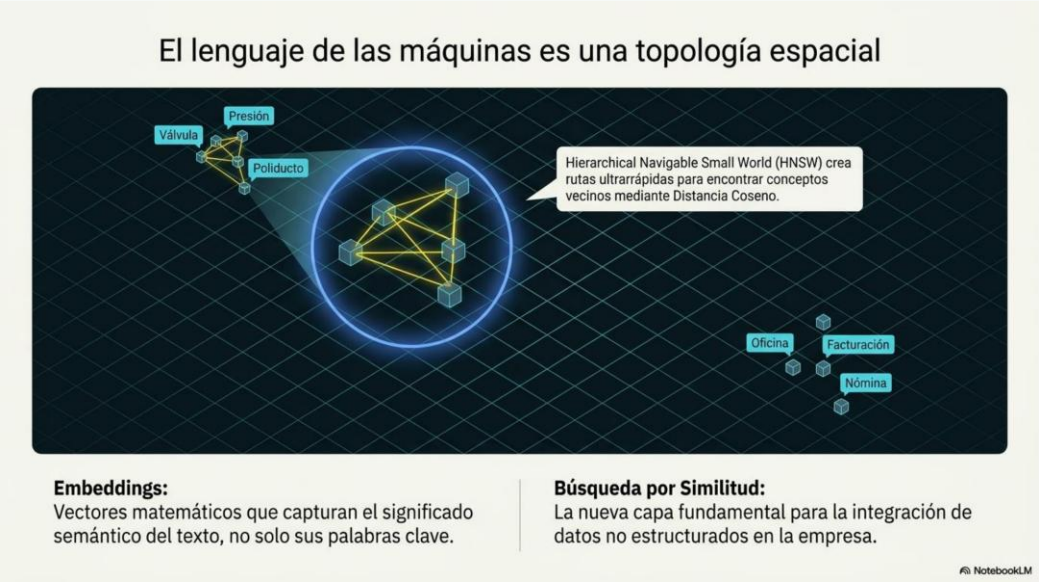
- Sin esquema: el significado está en el texto, no en columnas
- Sin dueño declarado: el manual vive en una carpeta compartida
- Sin vigencia explícita: nadie certifica qué versión rige
- Sin forma de consultarlo programáticamente

La capa vectorial no inventa una disciplina nueva: le aplica al documento las cuatro preguntas que ya le hacíamos a una tabla —quién es el dueño, qué esquema tiene, qué latencia promete y cómo se mide su calidad.

10

Del texto a la geometría: embeddings

Bloque 1 · el significado representado como posición en un espacio vectorial



LO QUE EL ARQUITECTO DEBE RETENER

- Un embedding traduce significado a coordenadas: lo semánticamente cercano queda espacialmente cerca
- La similitud se mide por distancia, no por coincidencia de palabras
- El índice aproximado hace la búsqueda viable a escala, a cambio de exactitud
- El modelo de embeddings es una dependencia versionada: cambiarlo obliga a reindexar todo

Decisión de arquitectura asociada: cambiar el modelo de embeddings es una migración de datos, no un cambio de configuración.

10

El almacén vectorial es un sistema más del ecosistema

Bloque 1 · la tesis central de la sesión, y su consecuencia operativa



EL PARALELO QUE ORDENA TODO

- Poblar el lakehouse exigió CDC, eventos y contratos; poblar el índice vectorial exige exactamente lo mismo
- Un índice sin pipeline de actualización nace obsoleto: el documento cambia y nadie se entera
- Reaparecen las tres formas de la sesión 7: la ingesta es consolidación, mantenerla fresca es propagación
- Y reaparece el dueño del dato: alguien tiene que responder por qué versión está indexada

Si el índice vectorial no tiene dueño, contrato ni mecanismo de actualización, no es un sistema: es una copia abandonada.

10

Decisión de arquitectura: motor dedicado o extensión de la base existente

Bloque 1 · el mismo dilema de siempre —producto especializado contra capacidad añadida—, aplicado a vectores

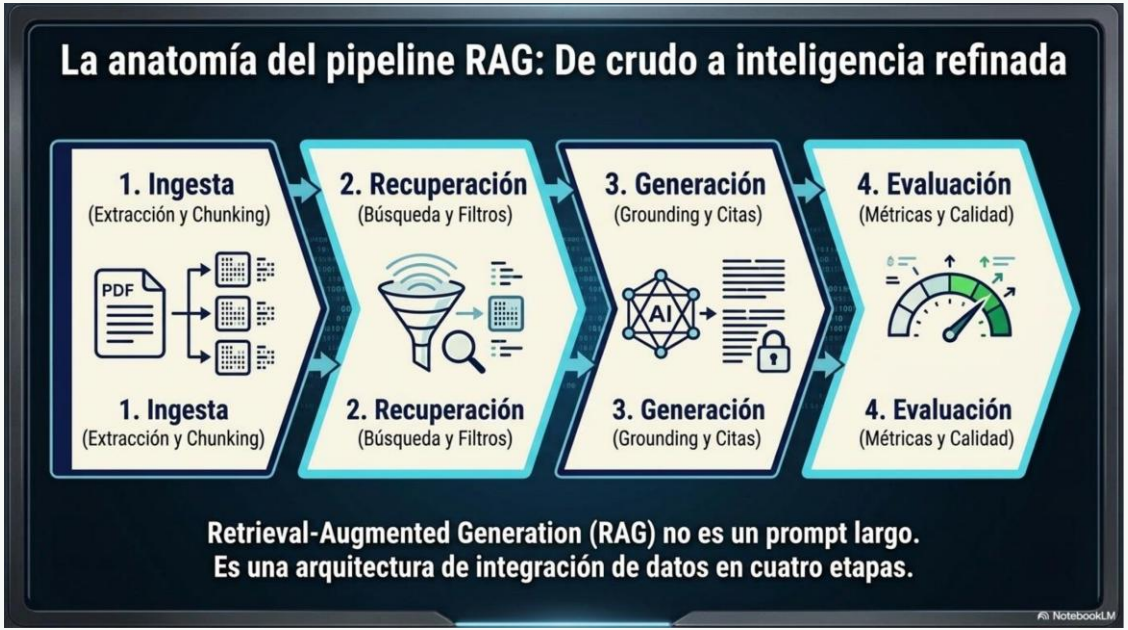
Criterio	Motor dedicado	Extensión de la base de datos
Naturaleza	Sistema nativo para vectores	Módulo añadido a la base relacional
Escala y rendimiento	Optimizado para millones de vectores y baja latencia	Suficiente donde el volumen es moderado y la relación con el dato estructurado manda
Complejidad operativa	Una pieza más de infraestructura que administrar	Aprovecha respaldos, seguridad y alta disponibilidad que ya existen
Gobierno	Catálogo y permisos propios, que hay que integrar	Hereda el modelo de permisos del motor existente

El veredicto no es técnico sino de contexto: motor dedicado cuando la recuperación semántica es el caso de uso central y masivo; extensión cuando lo que se busca es gobernar todo en un solo ecosistema.

10

El pipeline de recuperación tiene cuatro etapas

Bloque 2 · no es un prompt largo: es una arquitectura de integración de datos



Cada etapa tiene sus decisiones, sus fallas típicas y su forma de medirse. Las recorremos una por una.

10

Etapa 1 — Ingesta: partir el documento y etiquetarlo

Bloque 2 · aquí se decide casi todo lo que después se puede o no se puede controlar



DECISIONES DE ESTA ETAPA

- La partición respeta la estructura del documento — títulos, tablas, párrafos— en lugar de cortar a ciegas
- El tamaño y el solape se eligen por tipo de documento, no con un número universal
- Los metadatos inyectados aquí son la única forma de imponer reglas de negocio sobre texto
- Entre ellos, el que decide la seguridad del sistema: la vigencia

Regla práctica: todo lo que el consumidor deba poder filtrar tiene que existir como metadato desde la ingesta.

10

Etapa 2 — Recuperación: filtrar antes de buscar

Bloque 2 · la similitud semántica no distingue un procedimiento vigente de uno derogado



DECISIONES DE ESTA ETAPA

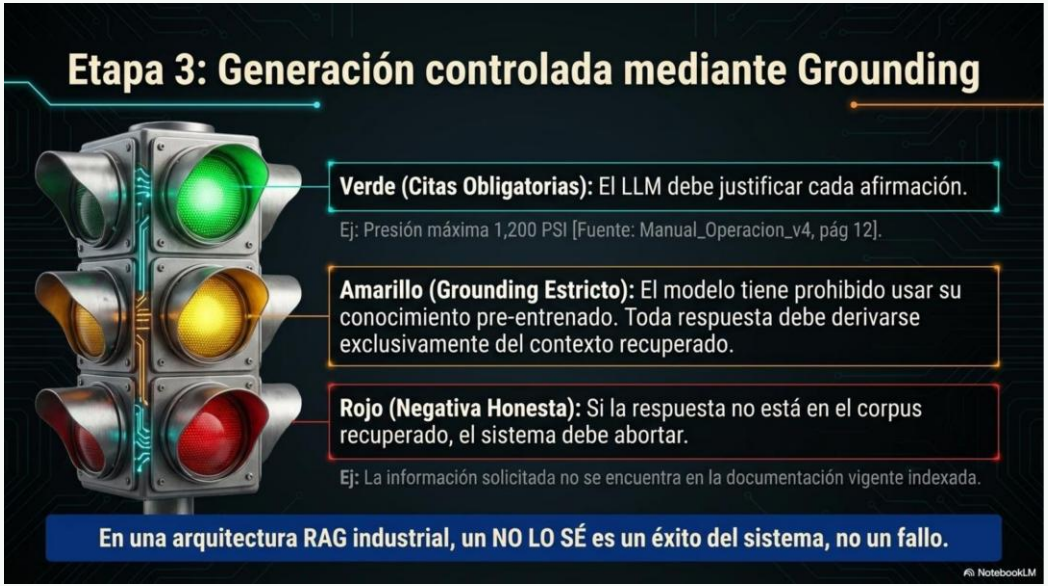
- El filtro por metadatos se aplica antes o junto con la búsqueda vectorial, nunca después
- La búsqueda híbrida combina similitud semántica con coincidencia léxica exacta —códigos, referencias, identificadores
- El reordenamiento posterior mejora la precisión a costa de latencia
- Cuántos fragmentos se recuperan es una decisión de costo y de calidad, no un valor por defecto

Un documento derogado recuperado es un incidente, no un resultado subóptimo: por eso el filtro es un control, no una optimización.

10

Etapa 3 — Generación controlada

Bloque 2 · el modelo responde solo con lo recuperado, cita su fuente y sabe decir que no sabe



LOS TRES CONTROLES

- Citas obligatorias: toda afirmación referencia documento, versión y sección
- Anclaje estricto: se prohíbe responder con conocimiento previo al contexto recuperado
- Negativa honesta: si la respuesta no está en el corpus, el sistema lo declara
- Los tres son requisitos de contrato, no comportamientos deseables

En una integración de misión crítica, «no lo sé» es una respuesta correcta del sistema, no una falla.

10 Etapa 4 — Evaluación: lo que separa la demo de la arquitectura

Bloque 2 · sin medición continua no hay forma de saber si el sistema se degradó



QUÉ SE MIDE Y POR QUÉ

- Anclaje: qué proporción de la respuesta está efectivamente respaldada por lo recuperado
- Relevancia de la recuperación: si el motor trajo los fragmentos correctos
- Tasa de desviación: cuántas respuestas se apartan de la fuente
- Y la condición de todo lo anterior: un conjunto de casos de referencia con su respuesta esperada

Es el mismo principio del contrato de datos de la sesión 9: lo que no declara un SLO medible, no se puede operar.

10

Dónde falla la búsqueda vectorial

Bloque 3 · encontrar un documento es un problema distinto de recorrer relaciones



EL LÍMITE, EN UNA FRASE

- La búsqueda por similitud localiza fragmentos parecidos a la pregunta
- No sabe recorrer relaciones: qué alimenta a qué, qué contrato cubre qué activo
- Las preguntas de varios saltos exigen una estructura de entidades y relaciones
- El grafo aporta esa estructura; el costo es construirla y mantenerla sincronizada

El grafo no reemplaza al índice vectorial: resuelve una clase de preguntas que el índice no puede responder.

10

Cuándo justifica el grafo su costo

Bloque 3 · criterios para decidir, no para elegir de antemano

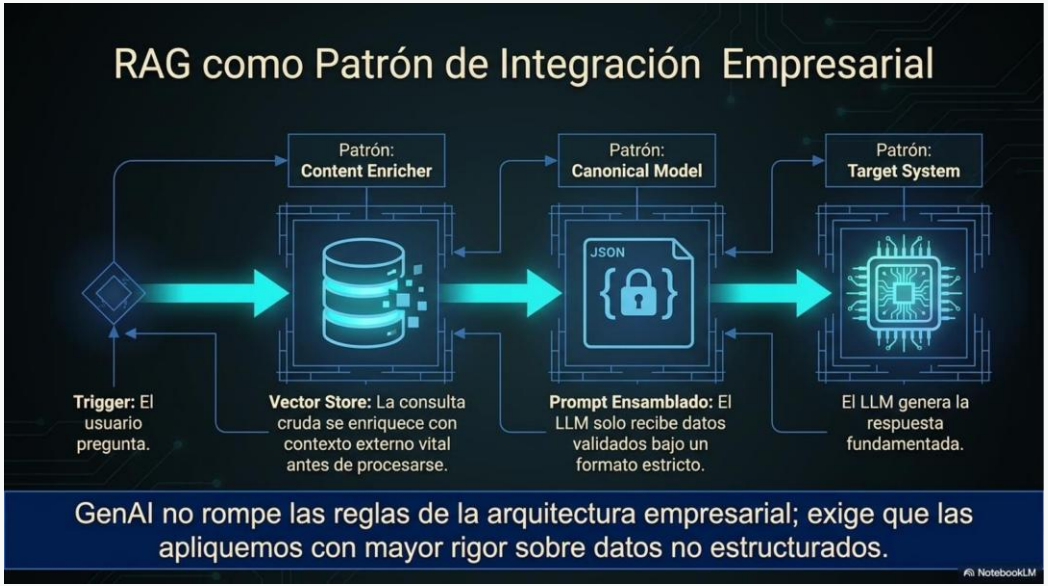
Dimensión	Recuperación vectorial	Recuperación sobre grafo
Tipo de pregunta	Localizar un documento o una definición	Relacionar entidades y razonar sobre la red
Estructura del dato	Texto fragmentado en pasajes	Entidades conectadas por relaciones tipadas
Costo de construcción	Bajo o medio: indexación relativamente directa	Alto: exige extraer entidades y relaciones del texto
Mantenimiento	Actualizar los fragmentos afectados	Recalcular relaciones cuando cambia el dominio

Patrón híbrido antes que disyuntiva: el grafo se construye solo para el subdominio donde las preguntas de relación justifican su mantenimiento.

10

Lo que estuvimos haciendo tiene nombre desde 2003

Bloque 3 · el cierre conceptual de la sesión



LA LECTURA CON EL VOCABULARIO DEL CURSO

- La consulta cruda se enriquece con contexto externo antes de procesarse: es un Content Enricher
- El contexto se entrega en un formato acordado y validado: es un modelo canónico de mensaje
- El modelo recibe solo lo que el contrato permite: es un Message Translator con filtro
- Y el sistema destino consume una salida con estructura declarada

La IA generativa no rompe las reglas de la arquitectura empresarial: obliga a aplicarlas con más rigor sobre datos que antes nadie gobernaba.

10

Práctica — Lápiz y papel

Bloque 4 · 40 min · en grupos · se entrega la hoja al cierre del bloque

PARTE A · EL CONTRATO DE INGESTA (20 min)

Para un corpus heterogéneo —manuales de operación, procedimientos, resoluciones regulatorias y comunicaciones de proveedores— especifique en una tabla: la estrategia de partición por tipo de documento, el conjunto mínimo de metadatos, la regla que determina la vigencia y, sobre todo, qué sistema o área certifica esa vigencia.

PARTE B · TRES PREGUNTAS, TRES TOPOLOGÍAS (20 min)

Dadas tres preguntas reales de operación, decida para cada una si la resuelve recuperación vectorial, recuperación sobre grafo, o ninguna de las dos. Justifique con los criterios del bloque 3 y declare qué latencia y qué nivel de trazabilidad promete en cada caso.

En la puesta en común: una de las tres preguntas tiene respuesta exacta en un sistema transaccional y no debería pasar por recuperación semántica. Detectarla es el objetivo del ejercicio.

10

Lanzamiento del Taller 2

Bloque 5 · 10% · se publica hoy · dos escenarios de integración sobre el temario de las sesiones 10 a 16

ESCENARIO A · SE IMPLEMENTA

Consulta documental gobernada

- Contrato del corpus y vigencia certificada
- Recuperación filtrada e híbrida
- Herramientas MCP con contrato
- Evaluación con casos de referencia

ESCENARIO B · SOLO DISEÑO

Conciliación con aprobación humana

- Proceso modelado en BPMN 2.0
- Frontera determinista declarada
- Matriz herramienta × permiso
- Gobierno y trazabilidad

QUÉ SE PUBLICA HOY

El enunciado, con cada parte marcada con la semana en que se habilita; y el corpus documental del caso: 19 documentos, con vigentes y derogados mezclados. Ninguno dice cuál es cuál.

Pueden arrancar hoy: el contrato de ingesta es lo que acaban de hacer en papel.

Se entrega y se sustenta en sesión aparte, al cierre del contenido. Recordatorio: hoy vence la Entrega 1 del Proyecto (15%).

10

Bibliografía de la sesión

LECTURAS OBLIGATORIAS

- Huyen, C. AI Engineering: Building Applications with Foundation Models. O'Reilly, 2025 — capítulos de RAG y de gestión de contexto.
- Lewis, P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS, 2020 — el artículo que da nombre al patrón.
- Hohpe, G. y Woolf, B. Enterprise Integration Patterns, 2003 — Content Enricher, Message Translator y Canonical Data Model: el vocabulario con el que leemos RAG en este curso.
- Documentación de un motor vectorial dedicado y de la extensión vectorial de un motor relacional, para contrastar ambos enfoques con criterios propios.

OPCIONALES

- Edge, D. et al. From Local to Global: A Graph RAG Approach to Query-Focused Summarization. arXiv:2404.16130, 2024.
- Malkov, Y. y Yashunin, D. Efficient and Robust Approximate Nearest Neighbor Search Using HNSW Graphs, 2018 — el índice detrás del almacén vectorial.
- Singh, A. et al. Agentic Retrieval-Augmented Generation: A Survey. arXiv:2501.09136, 2025 — puente hacia la sesión 11.
- Kleppmann, M. Designing Data-Intensive Applications, 2017 — sistemas derivados y propagación de cambios.
- ISO/IEC 42001:2023 — gestión de sistemas de IA: trazabilidad y control, para la sesión 16.