12

SESIÓN 12

Protocolos de integración agéntica: MCP, A2A y el AI Gateway

Semana 12 · 3 horas (180 min)

12 Objetivos y preparación

OBJETIVOS DE APRENDIZAJE

1. Explicar la arquitectura de MCP —host, cliente, servidor; tools, resources y prompts— y el problema N × M que resuelve
2. Leer la revisión 2026-07-28 como decisiones de diseño de protocolo, no como una lista de cambios
3. Decidir cuándo aplica MCP y cuándo A2A, y ubicar el AI Gateway como punto de gobierno

LECTURAS (≤ 85 MIN)

- Especificación MCP, revisión 2026-07-28 — arquitectura y registro de cambios
- A2A Protocol — introducción y Agent Card
- Opcional: «Code execution with MCP», de Anthropic

ACTIVIDAD DETONANTE (LMS)

Conectar M agentes con N sistemas exigía M × N integraciones a medida. Explique en dos líneas cómo un protocolo estándar convierte eso en M + N, y dónde vio este mismo argumento antes en el curso.

12 Agenda de la sesión (180 min)

Bloque	Min	Actividad	Objetivo
0	5	Apertura: el problema que resuelve un protocolo	—
1	40	MCP como adaptador: roles, primitivas y transportes	1
2	35	El protocolo maduró: qué cambió en la revisión 2026-07-28	2
R	**15**	**Receso**	**—**
3	30	A2A, la frontera de organización y la gobernanza de los protocolos	3
4	40	Práctica en papel: repartir las primitivas y resolver el estado	1 y 2
5	15	El catálogo que no cabe, el AI Gateway y cierre	3

La práctica se resuelve con lápiz y papel. El servidor MCP se implementa en el Escenario A del Taller 2, no en clase.

12 El recorrido de la sesión

De qué problema resuelve un protocolo, a qué significa que ese protocolo haya madurado

1

MCP como adaptador

Host, cliente y servidor; las tres primitivas; los transportes

2

El protocolo maduró

Sin estado, descubrimiento, caché, trazas y política de deprecación

3

A2A y las fronteras

La Agent Card, la frontera de organización y quién gobierna los estándares

4

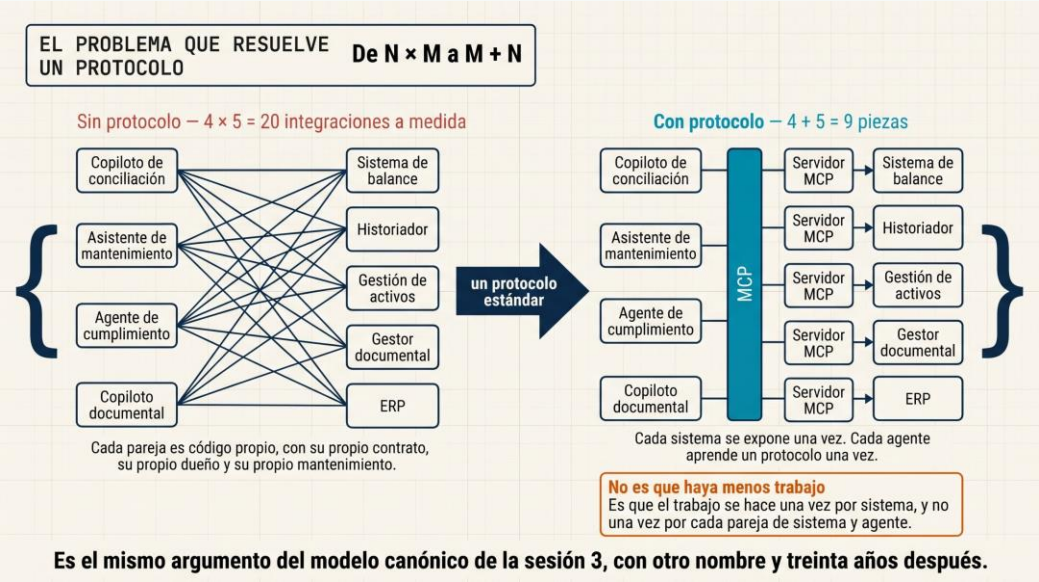
Aplicar

Práctica en papel, el AI Gateway y el servidor del Taller 2

La tesis de la sesión: MCP se volvió aburrido, y esa es exactamente la señal que buscábamos. Dejó de ser un protocolo de IA y se convirtió en un protocolo de integración.

12 El problema que resuelve un protocolo

Bloque 0 · la apertura, y la respuesta a la actividad detonante



LO QUE HAY QUE VER AQUÍ

- Sin protocolo, cada pareja de agente y sistema es código propio, con su contrato y su dueño
- Con protocolo, cada sistema se expone una vez y cada agente aprende el protocolo una vez
- No desaparece el trabajo: se reparte por sistema en lugar de por pareja
- Es el argumento del modelo canónico de la sesión 3, con otro nombre

Ningún estándar elimina la integración. Lo que elimina es la multiplicación.

12 Los tres roles: host, cliente y servidor

Bloque 1 · la arquitectura mínima, antes de cualquier detalle de protocolo

HOST

La aplicación donde vive el modelo

- Gestiona el bucle y el contexto
- Decide qué servidores registrar
- Aplica permisos y presupuesto
- Es el runtime de la sesión 11

CLIENTE

Una conexión con un servidor

- Lo crea el host, uno por servidor
- Relación estrictamente 1:1
- Traduce entre el host y el protocolo
- Aísla fallas: si cae uno, siguen los demás

SERVIDOR

Expone las capacidades de un sistema

- Implementa las herramientas
- Guarda las credenciales del destino
- Declara su catálogo y su versión
- Puede ser de un tercero

Un host tiene muchos clientes y cada cliente habla con exactamente un servidor. Esa relación 1:1 es la que permite otorgar permisos y aislar fallas por servidor, y no por agente.

12 Las tres primitivas, y quién decide que entren al contexto

Bloque 1 · la distinción que más se equivoca al diseñar un servidor

Primitiva	Qué es	Quién la controla	Ejemplo en el caso
tools	Acciones que pueden ejecutarse, con parámetros y efectos declarados	El modelo decide invocarla	consultar_balance_volumetrico(tramo, periodo)
resources	Contexto de solo lectura, identificado por URI	La aplicación decide incluirlo	El listado de tramos válidos con su MAOP
prompts	Plantillas reutilizables de interacción	La persona la elige explícitamente	«Investigar una diferencia de tramo»

La distinción no es cosmética: define quién decide que ese dato entre al contexto —el modelo, la aplicación o la persona—. Convertir todo en herramienta le entrega al modelo decisiones que no le corresponden.

12 Transportes, y el servidor leído con el vocabulario del curso

Bloque 1 · cierre del bloque: qué es realmente un servidor MCP

LOS DOS TRANSPORTES

- stdio: el servidor es un proceso hijo del host. Local, sin red, sin autenticación de red
- Streamable HTTP: el servidor es remoto, con autorización OAuth y posibles intermediarios
- HTTP+SSE quedó deprecado*; no se adopta en diseños nuevos
- La elección no es técnica sino de frontera: ¿el servidor vive dentro de la máquina o fuera?

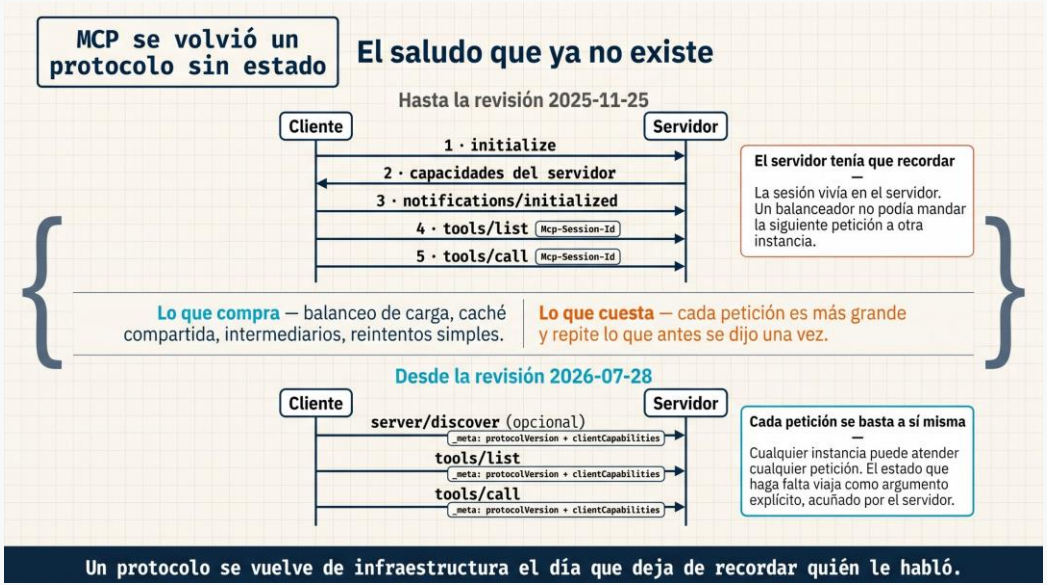
LO QUE YA SABEMOS NOMBRAR

- Un servidor MCP es un Channel Adapter: conecta un sistema a un canal con un formato acordado
- Y es un adaptador en el sentido hexagonal de la sesión 4: traduce entre el dominio y el exterior
- El catálogo de herramientas es el contrato de servicio publicado
- Tiene dueño, versión, latencia comprometida y semántica de error, como cualquier adaptador

No hay una disciplina nueva que aprender para construir un servidor MCP. Hay una disciplina vieja que aplicar, y un protocolo nuevo en el que publicarla.

12 El saludo que ya no existe

Bloque 2 · el cambio de fondo de la revisión 2026-07-28



LA DECISIÓN DE DISEÑO

- Desaparece el handshake de initialize y desaparecen las sesiones de protocolo
- Cada petición lleva su versión y sus capacidades en _meta, y se basta a sí misma
- Cualquier instancia del servidor puede atender cualquier petición
- El estado que deba sobrevivir viaja como argumento explícito acuñado por el servidor

Sin estado no significa sin memoria: significa que la memoria es explícita y tiene nombre.

12 Los cinco cambios, leídos como decisiones de arquitectura

Bloque 2 · ninguno de los cinco es un problema de inteligencia artificial

Qué cambió	Qué compra	La preocupación clásica que resuelve
Se eliminan las sesiones de protocolo	Balanceo de carga, intermediarios y caché compartida	Escalabilidad horizontal
server/discover de implementación obligatoria	Negociación de versión explícita y sondeo de compatibilidad	Compatibilidad, como en el schema registry de la sesión 5
ttlMs y cacheScope exigidos en los listados	El servidor declara cuánto dura su respuesta y quién puede guardarla	Frescura frente a costo, como en HTTP
Contexto de traza de OpenTelemetry en _meta	Una invocación se puede seguir de extremo a extremo	Observabilidad y auditoría
Política de deprecación con ventana de 12 meses	Previsibilidad para quien ya integró	Gobierno del ciclo de vida, como en la sesión 16

Son los cinco problemas de cualquier protocolo empresarial, resueltos en el mismo orden histórico en que los resolvieron HTTP, SOAP y AMQP.

12 MRTR: el servidor dejó de llamar al cliente

Bloque 2 · cómo se pide algo cuando nadie puede iniciar una conversación de vuelta

ANTES

- El servidor iniciaba peticiones hacia el cliente
- Así funcionaban sampling, elicitation y roots/list
- Exigía un canal abierto y un cliente que supiera atender peticiones entrantes

AHORA

- El servidor responde InputRequiredResult con lo que le falta
- El cliente reintenta la petición original incluyendo las respuestas
- Todo resultado declara su resultType: completo o requiere entrada

Invertir la dirección de la petición es lo que permite que haya un intermediario sin estado en medio. El servidor ya no llama a nadie: responde que le falta algo y espera el reintento.

12 Lo que queda deprecado, y hacia dónde migra

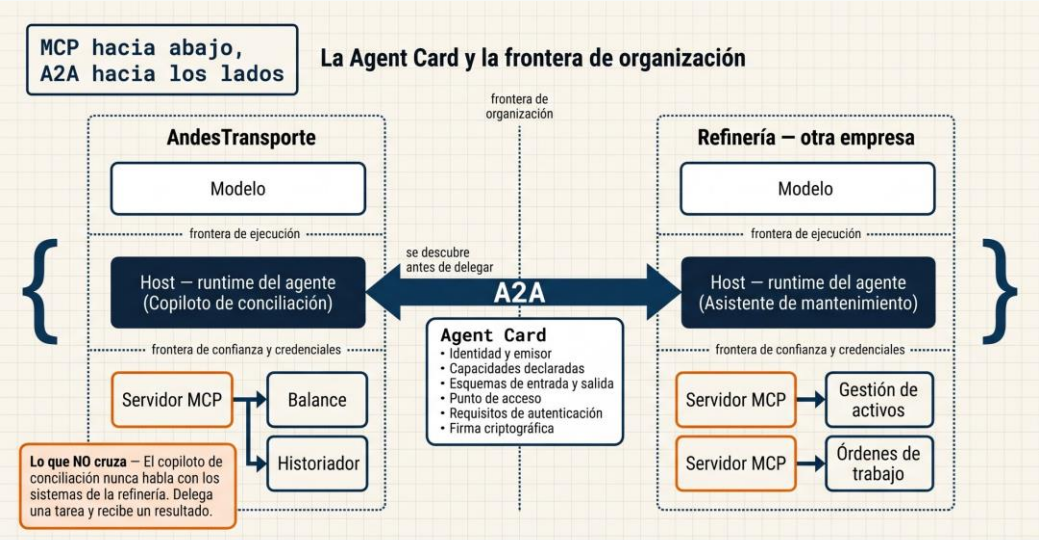
Bloque 2 · una ventana de doce meses y un registro público de lo que va a desaparecer

Funcionalidad deprecada	Migración sugerida
Roots	Pasar directorios o archivos como parámetros de herramienta, URIs de recurso o configuración del servidor
Sampling	Integrar directamente con la API del proveedor de modelos
Logging	Escribir a stderr en stdio, o usar OpenTelemetry
Transporte HTTP+SSE	Migrar a Streamable HTTP
Registro dinámico de clientes OAuth	Client ID Metadata Documents

Deprecado no es removido: sigue funcionando durante la ventana. Lo que importa para un arquitecto es que exista la ventana, que esté publicada y que haya un registro consultable. Eso es exactamente lo que exigimos a un contrato de datos en la sesión 9.

12 La Agent Card y la frontera de organización

Bloque 3 · lo que cambia cuando el interlocutor es de otra empresa



La Agent Card es a A2A lo que el catálogo de herramientas es a MCP: el contrato publicado. Lo que cambia es con quién se firma.

LO QUE HAY QUE VER AQUÍ

- Cada organización tiene su propio modelo, su propio host y sus propios servidores MCP
- Lo único que cruza entre empresas es la delegación de una tarea, nunca el acceso a los sistemas
- La Agent Card se descubre y se verifica antes de delegar: identidad, capacidades y firma
- Aparecen las tres fronteras del curso, cada una con su propio mecanismo de control

La Agent Card es a A2A lo que el catálogo de herramientas es a MCP: el contrato publicado. Lo que cambia es con quién se firma.

12 MCP o A2A: el criterio para decidir

Bloque 3 · no son alternativas que compitan, son capas distintas del mismo diseño

Dimensión	MCP	A2A
Dirección	Vertical: del agente a su herramienta	Horizontal: de un agente a otro agente
Qué se publica	El catálogo de herramientas con sus esquemas	La Agent Card firmada criptográficamente
Qué se delega	Una invocación concreta y acotada	Una tarea, posiblemente de larga duración
Quién responde por el resultado	Tu propio runtime	La organización del otro agente
Qué frontera cruza	Confianza y credenciales	Organización

La pregunta que decide: ¿quiero ejecutar algo, o quiero que alguien más se haga cargo de algo? Lo primero es MCP; lo segundo es A2A.

12 Quién gobierna estos protocolos

Bloque 3 · la diferencia entre un formato de proveedor y un estándar con casa neutral y política publicada

LA LÍNEA DE TIEMPO

- Abril de 2025: Google publica A2A; en junio lo dona a la Linux Foundation
- Agosto de 2025: el protocolo ACP de IBM se fusiona con A2A
- Diciembre de 2025: Anthropic dona MCP a la Agentic AI Foundation, con Block y OpenAI como cofundadores
- Marzo de 2026: A2A llega a la versión 1.0, con Agent Cards firmadas
- Agosto de 2026: A2A se suma también a la Agentic AI Foundation

QUÉ SIGNIFICA

La AAIF es un fondo dirigido de la Linux Foundation. Cada proyecto conserva sus mantenedores, su especificación y su calendario: es colocación bajo una misma casa, no una fusión.

La fundación aporta neutralidad e infraestructura; no dicta la dirección técnica.

Para un arquitecto esto no es dato de cultura general: es la diferencia entre apostar por el formato de un proveedor y apostar por un estándar con gobierno neutral y política de deprecación publicada.

12 Práctica — Lápiz y papel

Bloque 4 · 40 min · en los grupos del Taller 2 · se entrega la hoja al cierre del bloque

PARTE A · REPARTIR LAS PRIMITIVAS (20 min)

Se entrega una lista de diez cosas que PetroAndes querría exponer a su copiloto. Para cada una, decidir si es un tool, un resource, un prompt, o si no pertenece al protocolo en absoluto. Justificar en una línea, nombrando quién decide que ese dato entre al contexto.

PARTE B · QUÉ SE ROMPE SIN ESTADO (20 min)

Una investigación de varios pasos que debe poder reanudarse. Con un protocolo sin sesiones: qué estado existe, cuál es efímero y cuál debe sobrevivir, dónde vive y cómo viaja. Luego: qué pasa si el mismo identificador llega dos veces, y qué ttlMs y qué cacheScope declararían para tools/list.

En la puesta en común: tres de las diez no pertenecen al protocolo, y cada una por una razón distinta. Encontrar las tres razones es el objetivo del ejercicio.

12 Práctica — Lápiz y papel

Bloque 4 · 40 min · en los grupos del Taller 2 · se entrega la hoja al cierre del bloque

PARTE A · REPARTIR LAS PRIMITIVAS (20 min)

Decidir si es un tool, un resource, un prompt, o si no pertenece al protocolo en absoluto. Justificar en una línea, nombrando quién decide que ese dato entre al contexto.

1. consultar_balance_volumetrico(tramo, periodo) (Cálculo exacto de pérdidas por tramo).
2. petroandes://transporte/maop (Listado en tiempo real de la Máxima Presión Operativa Admisible por cada oleoducto) .
3. investigar_diferencia_volumetrica (Plantilla de interacción para diagnosticar caídas anómalas de presión) .
4. manuales_operacion_valvulas_scada (Corpus de documentos PDF no estructurados de proveedores de SCADA).
5. crear_ticket_mantenimiento_sap(equipo_id, hallazgo) (Registro de orden de trabajo en el ERP).
6. petroandes://scada/ayacucho/pressures (URI de lectura de series de tiempo del historiador AVEVA PI).
7. plantilla_reporte_regalias_anh (Formato estandarizado de reporte para la Agencia Nacional de Hidrocarburos).
8. llave_privada_firmado_scada (Credencial de cifrado de controladores industriales PLC).
9. calcular_emisiones_flaring(volumen_gas) (Calculadora determinista de la huella de carbono).
10. petroandes://hse/contactos_emergencia (Matriz de contactos de atención a derrames).

En la puesta en común: tres de las diez no pertenecen al protocolo, y cada una por una razón distinta. Encontrar las tres razones es el objetivo del ejercicio.

12 Práctica — Lápiz y papel

Bloque 4 · 40 min · en los grupos del Taller 2 · se entrega la hoja al cierre del bloque

PARTE A · REPARTIR LAS PRIMITIVAS (20 min)

Decidir si es un tool, un resource, un prompt, o si no pertenece al protocolo en absoluto. Justificar en una línea, nombrando quién decide que ese dato entre al contexto.

Elemento	Primitiva MCP	Quién decide la entrada al contexto	Justificación Arquitectónica
1. consultar_balance_volumetrico(tramo, periodo)			
2. petroandes://transporte/maop			
3. investigar_diferencia_ volumetrica			
4. llave_privada_firmado_scada			
5. crear_ticket_mantenimiento _sap(equipo_id)			

En la puesta en común: tres de las diez no pertenecen al protocolo, y cada una por una razón distinta. Encontrar las tres razones es el objetivo del ejercicio.

12 Cuando el catálogo no cabe en el contexto

Bloque 5 · el problema que aparece cuando el ecosistema crece, y su respuesta



LA LECTURA ARQUITECTÓNICA

- Con cientos de herramientas, el catálogo consume el contexto antes de leer la pregunta
- Y cada resultado intermedio vuelve a pasar por el modelo, que cobra por verlo
- La respuesta es divulgación progresiva: leer solo la definición que hace falta
- Y ejecución en código: filtrar y unir donde viven los datos, no en el contexto

Es la regla de siempre —no hagas pasar los datos por el orquestador— con una unidad de costo nueva.

12 Del API Gateway al AI Gateway

Bloque 5 · el mismo punto de gobierno de siempre, con dos unidades nuevas que medir

QUÉ APORTA

- Enrutamiento entre varios modelos y proveedores
- Control de costo y de cuota, medido en tokens
- Caché semántica de respuestas equivalentes
- Guardrails de entrada y de salida
- Registro de auditoría de cada invocación de herramienta
- Enmascaramiento de PII
- DLP (Data Loss Prevention)
- Balanceo de carga horizontal sin estado (stateless load balancing)* entre múltiples instancias de Servidores MCP.

DÓNDE VIVE EN EL DIAGRAMA

- Entre los hosts y los proveedores de modelos
- Y entre los hosts y los servidores MCP corporativos
- Es decir: sobre las dos fronteras que vimos en el bloque 3
- Que un protocolo sin estado permita intermediarios es justo lo que lo hace posible

No es una categoría de producto nueva: es el punto de gobierno de siempre, aplicado a un footprint donde las unidades que se miden son tokens y herramientas invocadas.

12 Cierre: por qué esta sesión es de arquitectura de integración

Bloque 5 · la tesis, lo que viene, y lo que se habilita hoy del Taller 2

LA TESIS, EN UNA LÍNEA

MCP se volvió aburrido, y esa es exactamente la señal que buscábamos: dejó de ser un protocolo de IA y se convirtió en un protocolo de integración.

- Sin estado, con descubrimiento, con caché declarada y con trazas
- Con política de deprecación publicada y casa neutral
- Y con un ecosistema que ya enfrenta su propio problema de escala

QUÉ SE HABILITA HOY

Del Taller 2, el servidor MCP del Escenario A: el criterio de qué es tool y qué es resource, el contrato completo por herramienta y la exigencia de declarar ttlMs y cacheScope.

Es lo que acaban de hacer en papel.

La sesión 13 responde lo que queda abierto: ya tenemos el protocolo, pero ¿quién corre el bucle, guarda los puntos de control y detiene el flujo para pedir aprobación?

MCP como adaptador | El protocolo maduró | A2A y las fronteras | **Aplicar**

12 Bibliografía de la sesión

LECTURAS OBLIGATORIAS

- Especificación del Model Context Protocol, revisión 2026-07-28 — visión de arquitectura y registro de cambios. El registro de cambios es la lectura más útil de toda la semana.
- A2A Protocol — introducción y especificación de la Agent Card.
- Hohpe, G. y Woolf, B. Enterprise Integration Patterns, 2003 — Channel Adapter: el patrón con el que leemos un servidor MCP.

OPCIONALES

- Anthropic. Code execution with MCP, 2025 — divulgación progresiva y ejecución en código.
- MCP joins the Agentic AI Foundation, diciembre de 2025 — el anuncio de la donación y sus términos.
- WebMCP — borrador del Community Group del W3C; emergente, no estándar.
- Documentación de un AI Gateway de cualquier proveedor, para contrastar con el API Management que ya conocen.