7

SESIÓN 7

Integración de datos: consolidación, federación y propagación

Semana 7 · 3 horas (180 min) · Caso PetroAndes · Cierra con el simulacro del Parcial 1

7 Objetivos y preparación

OBJETIVOS DE APRENDIZAJE

1. Distinguir las tres formas de integrar datos —consolidación, federación y propagación— por su intención arquitectónica
2. Decidir cuál aplica a cada flujo según dueño del dato, latencia, redundancia y costo
3. Prepararse para el formato del Parcial 1 mediante simulacro cronometrado

LECTURAS PREVIAS (≤ 70 MIN)

- White, C. Data Integration: Using ETL, EAI and EII Tools — la taxonomía original
- DAMA-DMBOK — capítulo de integración de datos e interoperabilidad
- Kleppmann, DDIA — derivación de datos: batch vs. stream

ACTIVIDAD DETONANTE (LMS)

El sistema analítico se puebla con exports manuales de Excel. ¿Copiaría los datos a un repositorio, los consultaría donde están, o los replicaría en línea? Justifique en 3 líneas.

7 Agenda de la sesión (180 min)

Bloque	Min	Actividad	Objetivo
0	5	Apertura y encuadre	—
1	35	Contexto, motivadores y punto de partida	1
2	45	Las tres formas de integrar datos	1
R	**15**	**Receso**	**—**
3	45	Práctica en papel: propiedad del dato y clasificación de flujos	2
4	35	Información del Parcial 1 y cierre	3

La práctica se resuelve con lápiz y papel; el computador solo se usa para consultar el caso y la documentación.

7 El recorrido de la sesión

Cuatro preguntas encadenadas: por qué, desde dónde, de qué formas y con cuál me quedo

1

Contexto y motivadores

¿Por qué integrar datos y qué problema de negocio resuelve?

2

¿De dónde partir?

Modelo conceptual, dueños del dato, canónico y características de los datos

3

Las tres formas

Consolidación · federación · propagación

4

Decidir y aplicar

Eje de decisión, herramientas por forma y clasificación de los flujos del caso

El error frecuente es empezar por el bloque 4: elegir la herramienta antes de saber quién es el dueño del dato y qué latencia exige el negocio.

7 Qué es integrar datos y por qué se hace

Bloque 1 · 35 min

DEFINICIONES

Gestionar el dato que viaja entre aplicaciones, almacenes, sistemas y organizaciones (DAMA, 2010).

Procedimientos y tecnologías para extraer, reestructurar, mover y cargar datos en almacenes operacionales o analíticos, en lote o en tiempo real (Giordano, 2011).

LO QUE AMBAS DEFINICIONES COMPARTEN

El dato cambia de contexto. Y al cambiar de contexto puede perder el significado que tenía en el sistema de origen: ese es el problema real.

MOTIVADORES

- Inteligencia de negocio y analítica
- Lenguaje común y gobierno de datos
- Vistas 360 y tableros de control
- Compartir datos entre aplicaciones
- Lidiar con la heterogeneidad del ecosistema

En PetroAndes, los cinco aparecen a la vez.

7 ¿De dónde partir? Cuatro preguntas antes de elegir nada

Bloque 2 · lo que ya vieron en las sesiones 2 y 3 se convierte aquí en insumo

Modelo conceptual

¿Qué entidades del negocio existen, independientes del sistema donde vivan?

Sesión 3

Dueños del dato

¿Qué sistema crea, modifica o destruye cada entidad? ¿Quién manda si hay conflicto?

Nuevo hoy

Modelo canónico

¿Qué formato común usamos para hablar entre modelos distintos?

Sesión 3

Características del dato

¿Qué volumen, frecuencia y latencia maneja cada flujo?

Sesión 2

Solo la segunda pregunta es nueva — y es la que más problemas evita: casi todo conflicto de integración de datos es, en el fondo, un conflicto de propiedad.

7 Un solo dueño por entidad

Bloque 2 · el criterio que define después la dirección de cada flujo

CÓMO SE DECIDE QUIÉN ES EL DUEÑO

1. ¿Qué sistema crea el dato por primera vez?
2. ¿Cuál mantiene la versión más actualizada?
3. ¿Dónde están implementadas las validaciones?
4. ¿A cuál le cree la organización cuando hay discrepancia?

La cuarta suele ser la única que el negocio responde sin dudar.

POR QUÉ IMPORTA PARA ESTA SESIÓN

- El dueño define la dirección del flujo: se propaga desde él, no hacia él
- Sin dueño único, la consolidación produce dos verdades y nadie sabe cuál reportar
- El dueño es quien puede comprometerse con un contrato de datos y una latencia
- Es la antesala del data mesh de la sesión 9: dominio dueño de su data product

En PetroAndes: ¿quién es el dueño del volumen de un tramo — custody transfer, el sistema de balance o SAP? La respuesta cambia toda la topología.

7 Dueños de los Datos

	SAP	Salesforce	Siebel	Ventas
Cliente	RW	R	RW	RW
Cuentas	R		RW	R
Tarjetas		RW	R	RW
Facturas	RW	R		RW
Pagos	RW	RW	RW	

Identifique los sistemas dueños de los datos en su modelo actual, así como qué sistemas, crean, modifican o destruyen los datos

7 Un solo Dueño

	SAP	Salesforce	Siebel	Ventas
Cliente	R	RW	R	R
Cuentas	R		RW	R
Tarjetas		R	R	RW
Facturas	RW	R		R
Pagos	RW	R	R	

Para definir qué sistema debe ser el dueño del dato, evalúe: ¿Qué sistema crea el dato? ¿Qué sistema maneja la información más actualizada? ¿Hay validaciones sobre los datos implementadas en algún sistema? ¿Hay un sistema al que se le "crea" sobre los demás?

7 Características del dato: volumen, frecuencia y latencia

Bloque 2 · las tres cifras que hay que conocer antes de elegir entre consolidar, federar o propagar

VOLUMEN

¿Cuánta información se intercambia por operación y en total?

SE MIDE EN

MB por corrida · registros por lote · GB/día · número de entidades

El cierre de balance mensual mueve millones de registros de custody transfer.

FRECUENCIA

¿Cada cuánto ocurre el intercambio y qué tan desigual es?

SE MIDE EN

eventos/segundo · corridas/día · relación pico sobre promedio

Las nominaciones se reciben una vez al mes, con todo el pico el primer día.

LATENCIA

¿Cuánto puede tardar el dato en volverse utilizable?

SE MIDE EN

p95 y p99 extremo a extremo · ventana de tolerancia del negocio

El reporte a la ANH tolera días; la alerta de anomalía, menos de un minuto.

QUÉ SUGIERE CADA COMBINACIÓN

Volumen alto + frecuencia baja + latencia tolerante

→ **consolidación**

Volumen bajo + dato que cambia rápido o que no se puede copiar

→ **federación**

Volumen unitario mínimo + frecuencia alta + latencia estricta

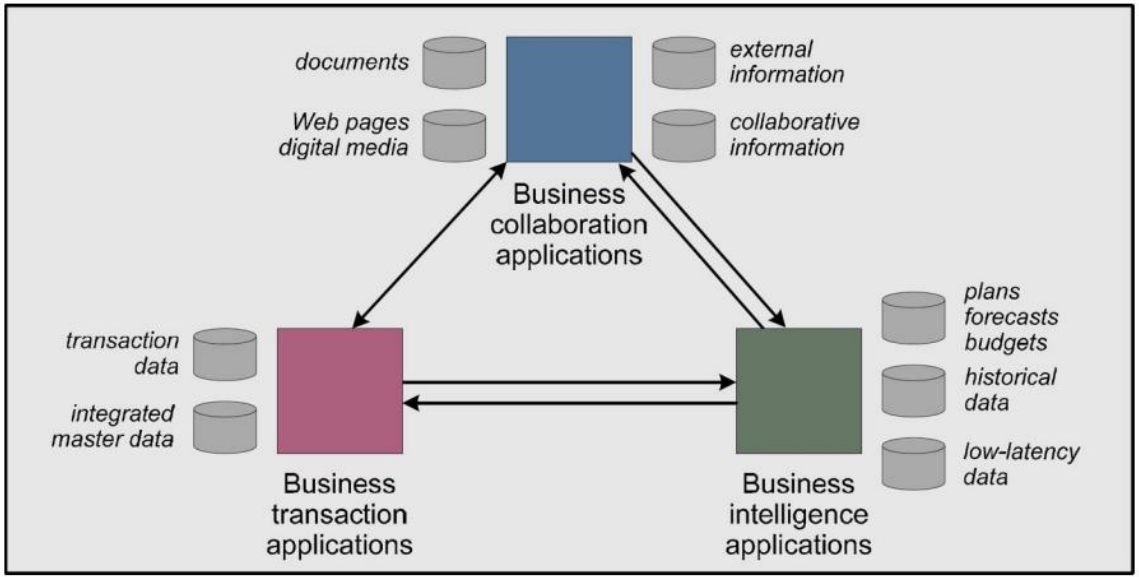
→ **propagación**

Volumen × frecuencia = throughput. Throughput alto más latencia estricta es la combinación más cara: prometerla donde el negocio tolera horas es gastar sin comprar valor.

7 Componentes de integración de datos

Bloque 2 · el criterio que define después la dirección de cada flujo

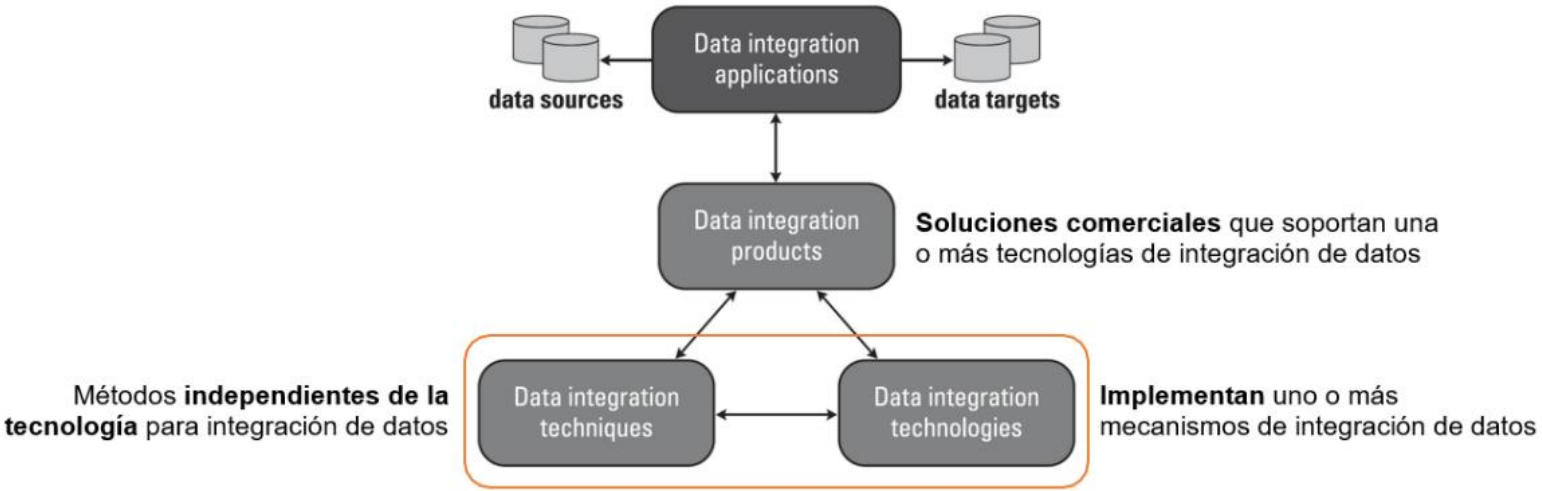
DEFINICIONES



7 Componentes de integración de datos

Bloque 2 · el criterio que define después la dirección de cada flujo

COMPONENTES DE SOLUCIÓN DE INTEGRACIÓN DE DATOS



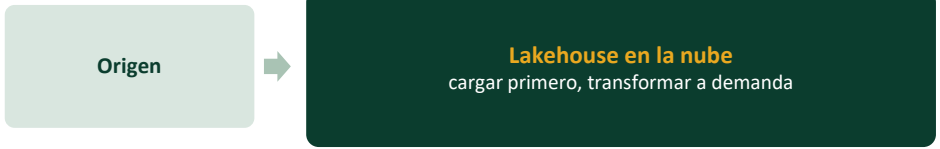
7 La nube invirtió el orden de la transformación

El cambio no fue de moda: fue de economía del almacenamiento y del cómputo

ETL · EL PASADO



ELT · EL PRESENTE



¿POR QUÉ CAMBIÓ EL ORDEN?

- El almacenamiento se volvió barato: ya no hace falta descartar antes de guardar
- El cómputo es elástico: el destino transforma bajo demanda y paga solo cuando corre
- Guardar el dato crudo permite responder preguntas que nadie había formulado al diseñar
- El costo se movió del servidor intermedio al consumo: aparece FinOps

Cuidado con el efecto colateral: cargar todo sin gobierno convierte el lakehouse en el pantano de datos que el ELT prometía evitar.

7 Las tres formas de integrar datos

Bloque 3 · se clasifican por intención, no por tecnología

CONSOLIDACIÓN

Copia los datos de varias fuentes a un repositorio persistente único

el dato se mueve y se queda

Ejemplo: el lakehouse analítico que reemplaza los Excel

FEDERACIÓN

Ofrece una vista virtual única de fuentes dispersas, sin mover los datos

el dato no se mueve

Ejemplo: una vista de consulta sobre contratos ANH, sin copiarlos

PROPAGACIÓN

Copia el dato de una ubicación a otra, en línea o casi en tiempo real

el dato se mueve y sigue vivo en el origen

Ejemplo: telemetría del poliducto hacia balance y alertas

También llamada replicación. DAMA y White usan «propagación»; la industria suele decir «replicación»: son la misma familia.

7 Consolidación: una copia persistente y única

Bloque 3 · el dato se mueve y se queda

FORMA 1

CUÁNDO ES LA RESPUESTA

- Análisis histórico que cruza muchas fuentes
- El consumidor tolera latencia de horas o días
- Se necesita reprocesar y reinterpretar el dato crudo
- Hay que preservar el dato tal como estuvo en una fecha

LO QUE CUESTA

- Crea redundancia: hay que decidir quién reconcilia
- La copia siempre va detrás del origen
- Almacenamiento y gobierno del repositorio
- Sin gobierno, se convierte en un pantano de datos

IMPLEMENTACIONES HOY

ETL y ELT, lakehouse con formatos de tabla abiertos, capas medallion, transformación en el destino.

EN PETROANDES

El lakehouse que reemplaza los Excel del sistema analítico.

7 Consolidación: una copia persistente y única

Bloque 3 · el dato se mueve y se queda

FORMA 1

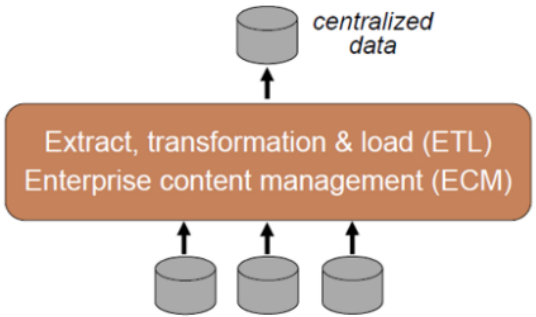


Imagen tomada de [1]

Consideraciones

Generalmente existe **latencia** entre la actualización en las fuentes de datos y el repositorio en el que se consolida.

Escenarios de uso

1. Repositorio para generar reportes históricos y análisis (**Bodegas de datos**)
2. Fuente para otras aplicaciones (**ODS** – Operational Data Store).

Mecanismos

La tecnología más común son los **ETL** (Extract, Transform and Load) o **ELT**, y los **ECM** (Enterprise Content Management) para data no estructurada como documentos o páginas web.

Ventajas

Permite que grandes volúmenes de datos sean **transformados** al consolidarlos. Al hacer los análisis **no** se **sobrecarga** la **fuente** de datos.

Desventajas

No es recomendable en escenarios de integración en **tiempo real**. Requiere **recursos** computacionales para **almacenamiento** y procesos de **consolidación**.

7 Federación: una vista virtual, sin mover el dato

Bloque 3 · el dato se queda donde su dueño lo tiene

FORMA 2

CUÁNDO ES LA RESPUESTA

- Consultas exploratorias o de baja frecuencia
- Copiar el dato está prohibido o es inconveniente
- El dato cambia tan rápido que una copia nace vieja
- Se quiere un punto único de consulta sin proyecto de migración

LO QUE CUESTA — Y LA ADVERTENCIA

- Cada consulta golpea los sistemas operativos en producción
- El rendimiento depende del más lento de las fuentes
- No elimina la redundancia de datos que ya existía
- Integra por interfaz: puede tapar el desorden en vez de removerlo (Frank)

IMPLEMENTACIONES HOY

Virtualización de datos, motores de consulta federada, tablas externas, capa semántica.

EN PETROANDES

Consultar el maestro de contratos ANH sin duplicarlo fuera de su sistema dueño.

7 Federación: una vista virtual, sin mover el dato

Bloque 3 · el dato se queda donde su dueño lo tiene

FORMA 2

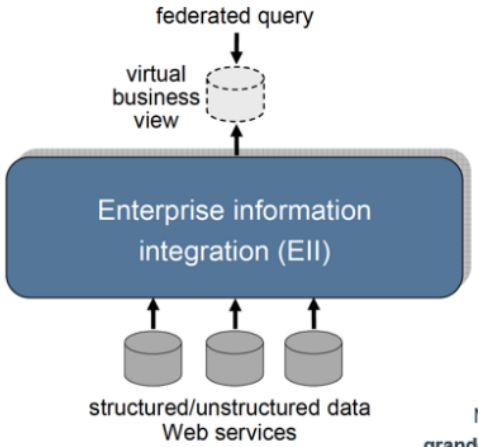


Imagen tomada de [1]

Consideraciones

Cuando una aplicación emite una consulta sobre la vista virtual, el motor de federación recupera los datos de las fuentes, los integra para que coincida con la vista y envía el resultado a la aplicación solicitante. Se extraen los datos de la fuente **bajo demanda**.

Escenarios de uso

1. Consultas operativas "sencillas" sobre datos actuales.
2. Ante políticas de seguridad o licenciamiento que prohíban la copia de datos.
3. Cuando los costos de consolidación exceden los beneficios o para una integración de corto plazo.

Mecanismos

La tecnología más común es **EII** (Enterprise Information Integration).

Ventajas

Permite acceso a los datos actuales sin necesidad de consolidar/mover datos a un nuevo repositorio.

Desventajas

No es recomendable en escenarios con **grandes volúmenes** de datos, ni con fuentes con problemas de **calidad** o necesidades de **transformación**. **Impacto** en el desempeño de las aplicaciones **fuente**.

7 Propagación: copiar en línea, hacia donde se necesita

Bloque 3 · el dato se mueve y sigue vivo en el origen

FORMA 3

CUÁNDO ES LA RESPUESTA

- Varios sistemas transaccionales deben compartir el mismo hecho
- La latencia tolerable se mide en segundos o menos
- El consumidor necesita reaccionar, no solo consultar
- Se requiere trazabilidad de cada cambio, no solo del estado final

LO QUE CUESTA

- Redundancia distribuida: muchas copias que pueden divergir
- Exige idempotencia y manejo de duplicados en el consumidor
- Acopla al esquema del origen si no media un contrato
- Operación permanente: no es un proyecto que termina

IMPLEMENTACIONES HOY

CDC de log, replicación transaccional, streaming sobre un log de eventos, outbox y reverse ETL.

EN PETROANDES

La telemetría del poliducto y el evento de factura emitida hacia balance.

7 Propagación: copiar en línea, hacia donde se necesita

Bloque 3 · el dato se mueve y sigue vivo en el origen

FORMA 3

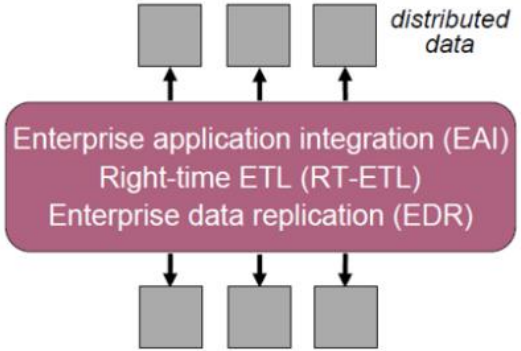


Imagen tomada de [1]

Consideraciones

Se definen reglas de propagación que determina cuándo es distribuido un dato.

Escenarios de uso

1. Integración de datos transaccionales en tiempo real.
2. Recuperación ante fallos.

Mecanismos

Las tecnologías más comunes son **EAI** (Enterprise Application Integration) y **EDR** (Enterprise Data Replication).
SOA.

Ventajas

Es utilizada en escenarios de actualización transaccional en tiempo real o cercana al tiempo real. Permite la propagación en doble sentido.

Desventajas

Dependiendo del producto utilizado hay consideraciones de desempeño, volúmenes de datos y tratamiento de los mismos.

7 El eje de decisión: seis preguntas antes de elegir

Bloque 4 · la herramienta se elige al final, nunca al principio

Pregunta	Consolidación	Federación	Propagación
¿El dato se mueve?	sí, y se queda	no	sí, y sigue vivo en origen
¿Crea copia persistente?	sí, una	ninguna	sí, varias
Latencia típica	horas – días	la de la fuente más lenta	segundos o menos
Carga sobre el origen	en la ventana de carga	en cada consulta	continua pero ligera
Quién reconcilia	el repositorio	nadie: no hay copia	cada destino
Riesgo principal	pantano de datos	tapar el desorden	divergencia entre copias

Séptima pregunta, la que decide en la práctica: ¿quién es el dueño del dato y a qué contrato puede comprometerse?

7 Lo que la taxonomía clásica no contemplaba

La clasificación es de 2005: sigue siendo válida, pero hay cuatro matices

El streaming no es solo propagación más rápida

Cuando el log se vuelve la fuente de verdad, cambia quién es el dueño del dato, no solo la velocidad.

La federación revivió

Los formatos de tabla abiertos y los motores de consulta federada hicieron viable lo que antes no rendía.

El reverse ETL invirtió la dirección

Propagación desde el repositorio analítico hacia la operación: el dato curado vuelve a donde se actúa.

Las tres se combinan en la misma arquitectura

No se elige una para toda la organización: se elige una por flujo, y conviven.

La pregunta de Frank sigue siendo la más incómoda: integrar por interfaz sin resolver la redundancia de datos es tapar el desorden, no removerlo.

7 El panorama de herramientas, por forma

Bloque 4 · criterio de arquitecto, no catálogo de proveedor

CONSOLIDACIÓN

- Suites clásicas: ODI, Pentaho, SAP Data Services, Talend
- Nube: Data Factory, Glue, CloudPak for Data
- Nueva generación: Fivetran, Airbyte, dbt para la transformación

FEDERACIÓN

- Virtualización: Denodo, TIBCO, SAP
- Motores de consulta federada y tablas externas
- Capa semántica sobre el lakehouse

PROPAGACIÓN

- Replicación: GoldenGate, Striim
- CDC de log: Debezium sobre Kafka Connect
- Streaming: Kafka, Redpanda, Pulsar

Los nombres cambian cada tres años; la pregunta que los ordena, no. Evalúe: ¿qué forma implementa?, ¿a qué latencia se compromete?, ¿qué contrato expone?

7 Práctica — Lápiz y papel

Bloque 3 · 45 min · en grupos · el computador solo para consultar el caso y la documentación

PARTE A · MATRIZ DE PROPIEDAD (20 min)

Para seis entidades del caso —medición de custody transfer, factura de transporte, contrato ANH, orden de mantenimiento, calidad de producto y nominación— complete a mano una tabla con: qué sistema la crea, cuál la modifica, cuál manda si hay discrepancia y qué latencia necesitan los demás. Marque en rojo las entidades sin dueño claro.

PARTE B · CLASIFICAR LOS FLUJOS (25 min)

Dibuje en una hoja los flujos entre esas entidades y sus consumidores. Para cada flecha escriba cuatro cosas: la forma elegida (consolidación, federación o propagación), la razón usando el eje de decisión, la latencia comprometida y quién es el dueño del contrato. Al menos un flujo debe ser federación y al menos uno debe ir en sentido inverso.

Se entrega la hoja al final del bloque. No se califica la sofisticación de la topología, sino la coherencia entre dueño, forma, latencia y contrato.

7 El mapa que deben poder defender

Referencia para la puesta en común: una lectura posible, no la única



El flujo más discutible: ¿los contratos ANH se federan o se consolidan? Depende de si el analítico necesita reconstruir su historia.

Cada flecha declara forma, latencia, dueño y contrato. Sin esas cuatro cosas, el diagrama es decorativo.

7 Bloque 4 — Simulacro del Parcial 1

35 min · el parcial es la próxima sesión

PARCIAL 1

1 · Tarjeta de escenario (5 min)

Un problema arquitectónico de PetroAndes, entregado antes del turno. Una tarjeta distinta por estudiante, tienen 5 min para preparar el pitch.

2 · Pitch (5 min)

Su solución explicada mientras dibuja en el tablero. Cronometrado

3 · Panel de preguntas (5 min)

Defensa técnica: dos preguntas ancla y una que cambia un supuesto

QUÉ SE CALIFICA

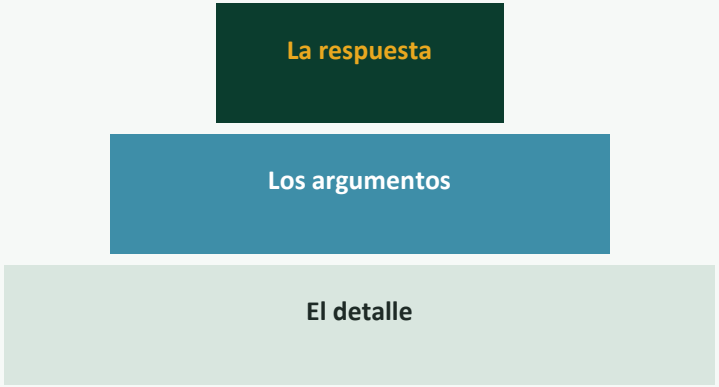
Corrección técnica y vocabulario canónico (30%) · trade-offs y alternativas descartadas (25%) · comunicación y estructura (20%) · manejo de preguntas y cambio de supuestos (20%) · anclaje en el caso (5%)

La rúbrica premia la capacidad de justificar y de diseñar topologías, no la búsqueda de una única respuesta perfecta.

7 Cómo estructurar la defensa técnica

El principio de la pirámide: la respuesta primero, el detalle al final

PARCIAL 1



Directa y conclusiva

«Este flujo lo resolvería con propagación por CDC.»

Tres razones clave

«Porque el dueño es SAP, la latencia exigida es de segundos y no quiero copia reconciliable.»

Datos de soporte

Volúmenes, contrato, retención y costo de operación.

Regla de oro: dibuje la topología mientras habla. Y si desconoce un dato técnico, no lo invente — diga «no tengo el dato exacto, pero lo razonaría de esta manera…».

En el simulacro: tres voluntarios hacen el ejercicio completo cronometrado y la clase califica con la rúbrica real.

7 La pregunta de síntesis de la sesión

Ticket de salida — y pregunta probable del panel

PARCIAL 1

Tome un flujo de su proyecto: ¿lo resolvería consolidando, federando o propagando, y qué consecuencia tiene esa elección sobre quién reconcilia el dato?

LO QUE EL PANEL ESCUCHA

Si nombra la forma por su nombre, si identifica al dueño del dato y si reconoce el costo de su elección en vez de venderla como gratis.

LA IDEA DE FONDO

Integrar datos no es moverlos más rápido: es decidir dónde vive la verdad y quién responde por ella.

Próxima sesión: Parcial 1 oral — formato ARB simulado, dos paneles paralelos, una tarjeta distinta por estudiante.

7 Bibliografía de la sesión

LECTURAS OBLIGATORIAS

- White, C. Data Integration: Using ETL, EAI and EII Tools to Create an Integrated Enterprise. TDWI Report Series, 2005.
- Mosley, M. y Brackett, M. The DAMA Guide to the Data Management Body of Knowledge (DAMA-DMBOK), 2010 — integración de datos.
- Kleppmann, M. Designing Data-Intensive Applications. O'Reilly — caps. 10 y 11.

OPCIONALES

- Yang, M. Use Data Integration Patterns to Build Optimal Architecture. Gartner, 2014.
- Frank, U. Integration — Reflections on a Pivotal Concept, 2008 (sesión 3).
- Debezium — documentación de CDC de log.
- Delta Lake / Apache Iceberg — formatos de tabla abiertos (sesión 9).