9

SESIÓN 9

Evolución de la arquitectura analítica: del almacén al lakehouse, data mesh y productos de datos

Semana 9 · 3 horas (180 min) · Caso PetroAndes · Se publica el Taller 2

9 Objetivos y preparación

OBJETIVOS DE APRENDIZAJE

1. Explicar la evolución bodega → lago → lakehouse y qué problema resuelve cada generación
2. Aplicar los cuatro principios del data mesh al caso y distinguirlo del data fabric
3. Especificar un data product con su contrato de datos: dueño, SLOs y puertos de salida

LECTURAS PREVIAS (≤ 90 MIN)

- Dehghani, Z. Data Mesh — capítulos de principios
- Formatos de tabla abiertos: qué aportan sobre archivos sueltos (ACID, versionado, evolución)
- Opcional: comparativo data mesh vs. data fabric

ACTIVIDAD DETONANTE (LMS)

¿Quién debería ser el dueño del data product «balance volumétrico conciliado»: TI corporativa, la VP de transporte o el equipo central de datos?

9 Agenda de la sesión (180 min)

Bloque	Min	Actividad	Objetivo
0	5	Apertura y encuadre	—
1	25	Analítica empresarial: por qué existe un sistema analítico aparte	1
2	50	Evolución de las arquitecturas analíticas: bodega, lago, lakehouse	1
R	**15**	**Receso**	—
3	35	Organización del dato: data mesh, data fabric y data products	2
4	35	Práctica en papel: ficha del data product	3
5	15	Lanzamiento del Taller 2 y cierre	—

La práctica se resuelve con lápiz y papel. Los mecanismos de integración —consolidación, federación y propagación— se vieron en la sesión 7 y aquí solo se referencian.

9 El recorrido de la sesión

De por qué existe la analítica, a cómo se organiza el dato y quién responde por él

1

Analítica empresarial

¿Por qué un sistema analítico aparte del transaccional?

2

Evolución de las arquitecturas

Bodega, lago y lakehouse: qué resolvió cada uno y qué rompió

3

Organización del dato

Data mesh, data fabric y el dato como producto con contrato

4

Aplicar y entregar

Ficha del data product y lanzamiento del Taller 2

La pregunta que recorre toda la sesión: cuando el dato analítico está mal, ¿a quién se le reclama? Las tres primeras generaciones no tienen una buena respuesta; el data mesh la convierte en principio de diseño.

9 Dos sistemas con propósitos distintos

Bloque 1 · por qué no basta con consultar la base del sistema operativo

SISTEMAS TRANSACCIONALES

Hacen girar las ruedas de la organización

- Registran la operación: una medición, un pedido, una orden de trabajo
- Uno o pocos registros por consulta
- Tareas repetitivas y preguntas conocidas de antemano
- Optimizados para escribir rápido y mantener la integridad

SISTEMAS ANALÍTICOS

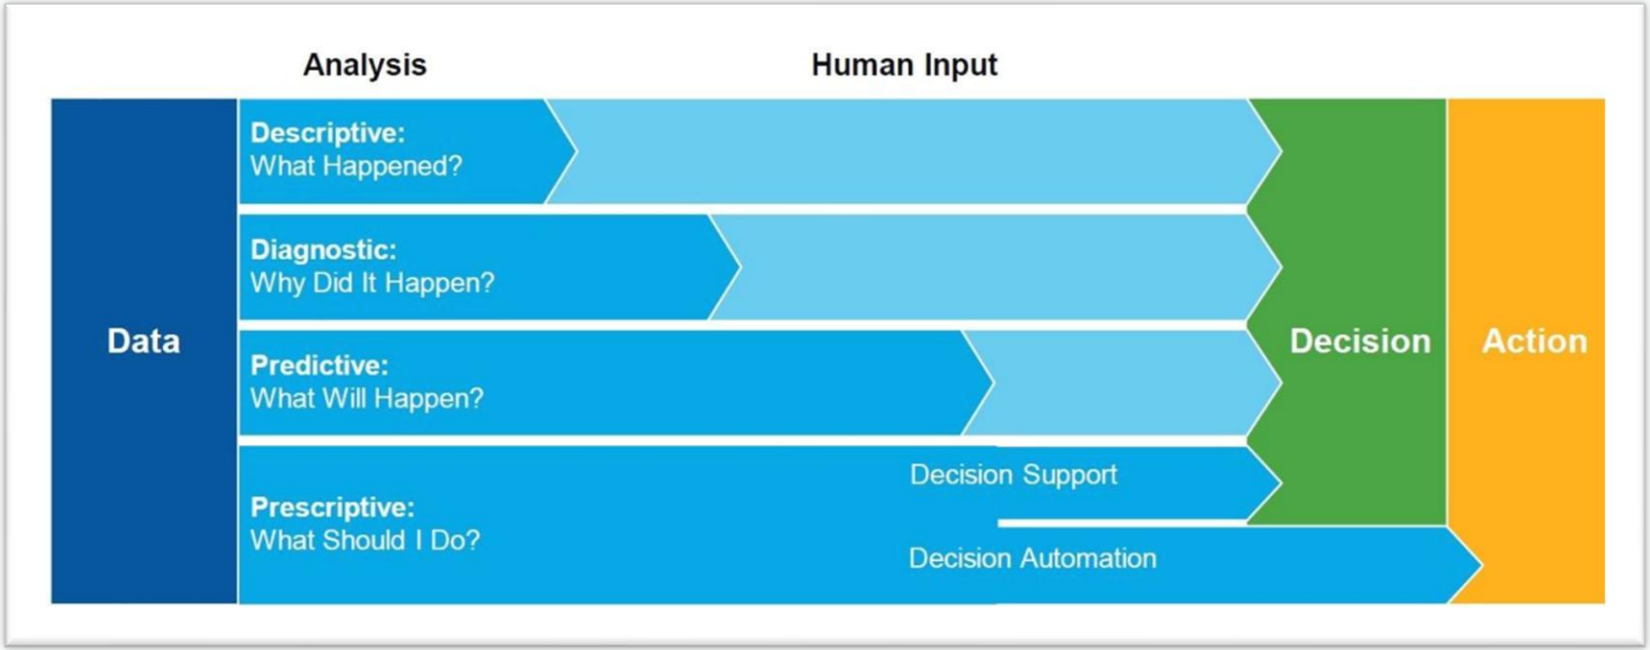
Ven girar las ruedas de la organización

- Preguntan por el comportamiento: cuánto, por qué, hacia dónde
- Cientos de miles o millones de registros por consulta
- Preguntas cambiantes, muchas no previstas al diseñar
- Optimizados para leer y cruzar grandes volúmenes

En PetroAndes el síntoma es conocido: el analista saca un Excel del sistema comercial a las 7 a. m. porque consultarlo en horario de operación lo pone lento. Esa es la frontera entre los dos mundos.

9 Qué le pedimos al sistema analítico

Bloque 1 · del reporte descriptivo a la predicción



9 Qué le pedimos al sistema analítico

Bloque 1 · del reporte descriptivo a la predicción

Dominio	Entradas	Pregunta que responde
Transporte	Balance volumétrico + histórico	¿Cuánto producto perdimos por tramo y cómo evoluciona?
Transporte	Telemetría + mantenimientos + patrullajes	¿Qué tramo tiene mayor riesgo de pérdida esta semana?
Refinación	Historiador + órdenes de trabajo	¿Esta bomba fallará en las próximas cuatro semanas?
Comercial	Ventas + precios regulados + paridad	¿Cuál será la posición frente al FEPC el próximo trimestre?
HSE	Operación + campañas de medición + factores	¿Cuánto metano emitimos por activo y dónde invertir primero?

Las dos primeras son descriptivas y las tres últimas predictivas. La diferencia no es el algoritmo: es que las predictivas exigen historia, calidad y linaje — y por eso fuerzan la arquitectura.

9 La bodega de datos y el modelo dimensional

Bloque 2 · la primera generación, y sigue viva donde el reporte manda

Hecho

El evento de negocio que se quiere analizar

una entrega en custody transfer

Dimensión

Las perspectivas por las que se analiza

tramo, producto, remitente, tiempo

Métrica

La variable numérica que mide el evento

volumen corregido, diferencia de balance

Kimball

Bus dimensional: data marts conformados que se integran por dimensiones compartidas. De abajo hacia arriba.

Inmon (CIF)

Bodega corporativa normalizada en 3FN como fuente única, con data marts derivados. De arriba hacia abajo.

Híbrida

Núcleo en 3FN y área de presentación dimensional. Es lo que la mayoría de organizaciones termina teniendo.

El modelo dimensional no murió: es la forma correcta de servir la capa de consumo, también dentro de un lakehouse.

9 Por qué la bodega sola dejó de alcanzar

Bloque 2 · principales retos reportados por organizaciones con bodega en producción

66%

No logra manejar el crecimiento de datos y de usuarios

60%

La bodega es muy compleja de administrar

38%

Altos costos iniciales y de mantenimiento

33%

Soluciones lentas: toman mucho tiempo para implementarse

19%

No pueden manejarse los distintos tipos de dato

Ninguno de los cinco es un problema de modelado: son de escala, costo y variedad. Por eso la respuesta no fue otro modelo dimensional sino otro tipo de almacenamiento.

9 Big data y el lago de datos

Bloque 2 · guardar primero, decidir después

Volumen

más dato del que una bodega soporta

Velocidad

llega continuo, no en ventanas

Variedad

no todo cabe en filas y columnas

«Una colección de instancias de almacenamiento de diversos activos de datos, guardados en una copia casi exacta —o exacta— del formato de origen, adicional a los almacenes originales» (Gartner).

Tres estilos de lago

1 · Conectar silos y consolidar fuentes en un solo lugar

2 · Zona de aterrizaje por streaming para información fresca

3 · Activación de innovación: combinación de ambos, descubrimiento

EL RIESGO QUE TRAJO

Sin esquema ni gobierno, el lago se vuelve un pantano: datos crudos que nadie sabe interpretar, sin dueño, sin calidad declarada y sin transacciones. El lakehouse nace justamente de ese fracaso.

9 Bodega de datos y lago de datos

Bloque 2 · dos respuestas a preguntas distintas

	Bodega de datos	Lago de datos
Datos	Relacional, estructurado	Relacional y no relacional
Esquema	Al escribir (schema-on-write)	Al leer (schema-on-read)
Almacenamiento	Alto costo, alto desempeño	Bajo costo
Calidad	Versión centralizada de la verdad	Datos crudos
Usuarios	Analistas de negocio	Científicos e ingenieros de datos
Analítica	Reportes, tableros, visualización	Machine learning, descubrimiento

La pregunta correcta no es cuál gana, sino qué dato va en cuál. El lakehouse intenta no tener que responderla.

9 La evolución analítica: del almacén al lakehouse

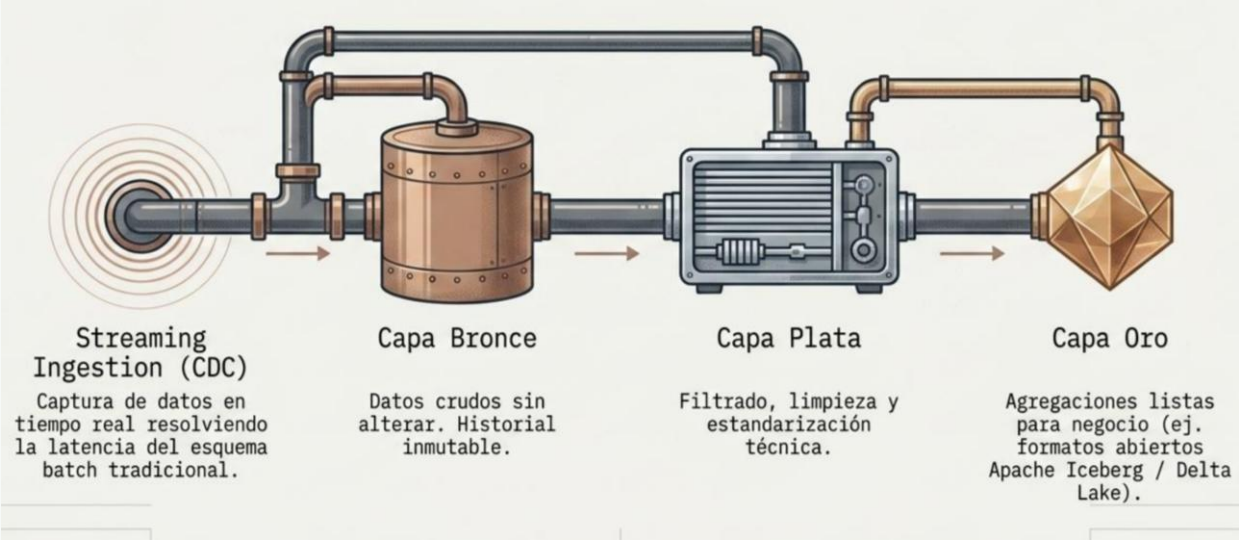
Bloque 2 · la tercera generación toma lo que funcionaba de cada una

	Data warehouse	Data lake	Lakehouse
Esquema	Escritura (rígido)	Lectura (flexible)	Abierto y evolutivo
Casos de uso	Exclusivo BI	Exclusivo ML	Unificado BI + ML
Transacciones	Inflexibles	Nulas	Soporte ACID completo
Riesgo o fallo	Silos rígidos	Pantano inmanejable	Estandarización de formato

Lo que lo hizo posible: los formatos de tabla abiertos sobre almacenamiento de objetos, que aportan transacciones ACID, evolución de esquema y consulta del estado en una fecha pasada sin duplicar el dato.

9 La refinería de datos: arquitectura medallion

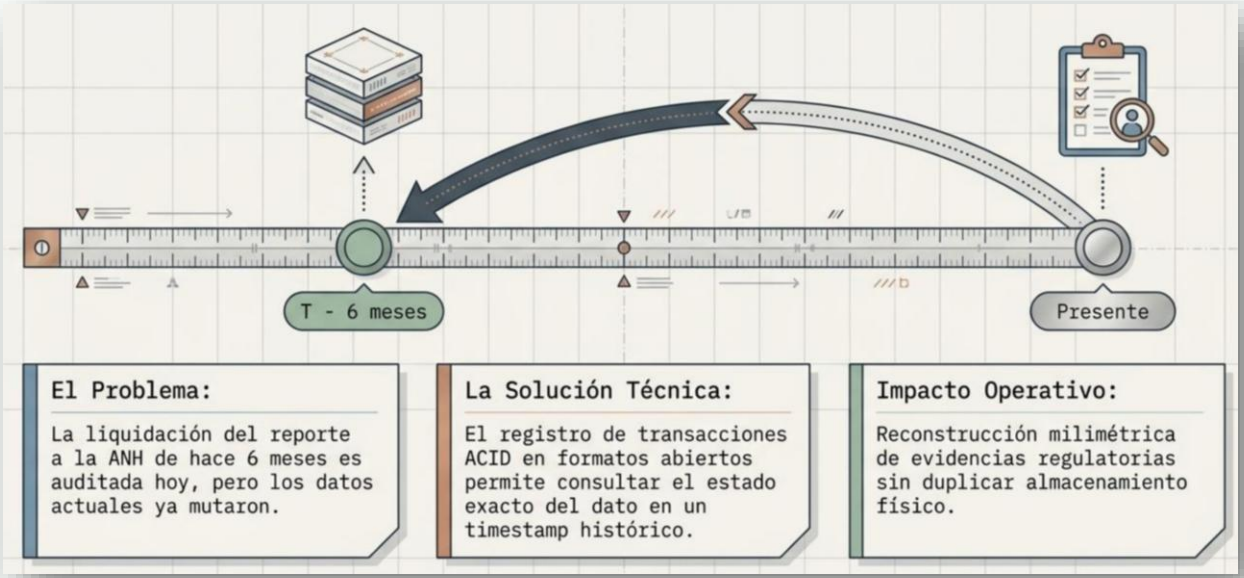
Bloque 2 · bronce guarda, plata limpia, oro sirve al negocio



La analogía es deliberada: igual que el crudo, el dato se refina por etapas y cada una tiene su especificación.

9 Versionado: el habilitador regulatorio

Bloque 2 · responder qué decía el dato el día que se reportó



9 Bodega y lago conviviendo: tres patrones

Bloque 2 · casi ninguna organización empieza de cero

1 · Convivencia

Los dos coexisten, conectados por catálogo y gobierno fuerte.

Integración semántica

2 · La bodega alimenta al lago

Se migra la historia procesada hacia el lago para habilitar nuevos usos.

Integración física

3 · La bodega como zona de resultados

El lago procesa y entrega al final; el ETL se vuelve ELT.

Integración física

El patrón 3 es el que más se parece a lo que hoy llamamos lakehouse, y explica por qué el ELT desplazó al ETL: ya no hace falta transformar antes de guardar.
Elegir patrón es una decisión de migración, no de tecnología: depende de cuánta historia hay y de quién opera hoy la bodega.

9 Dónde encajan las tres formas de integrar

Bloque 2 · costura con la sesión 7: los mecanismos no cambian, cambia el destino

Propagación

CDC y streaming alimentan la capa bronce de forma continua

Consolidación

El lakehouse es el repositorio persistente donde el dato se queda y se refina

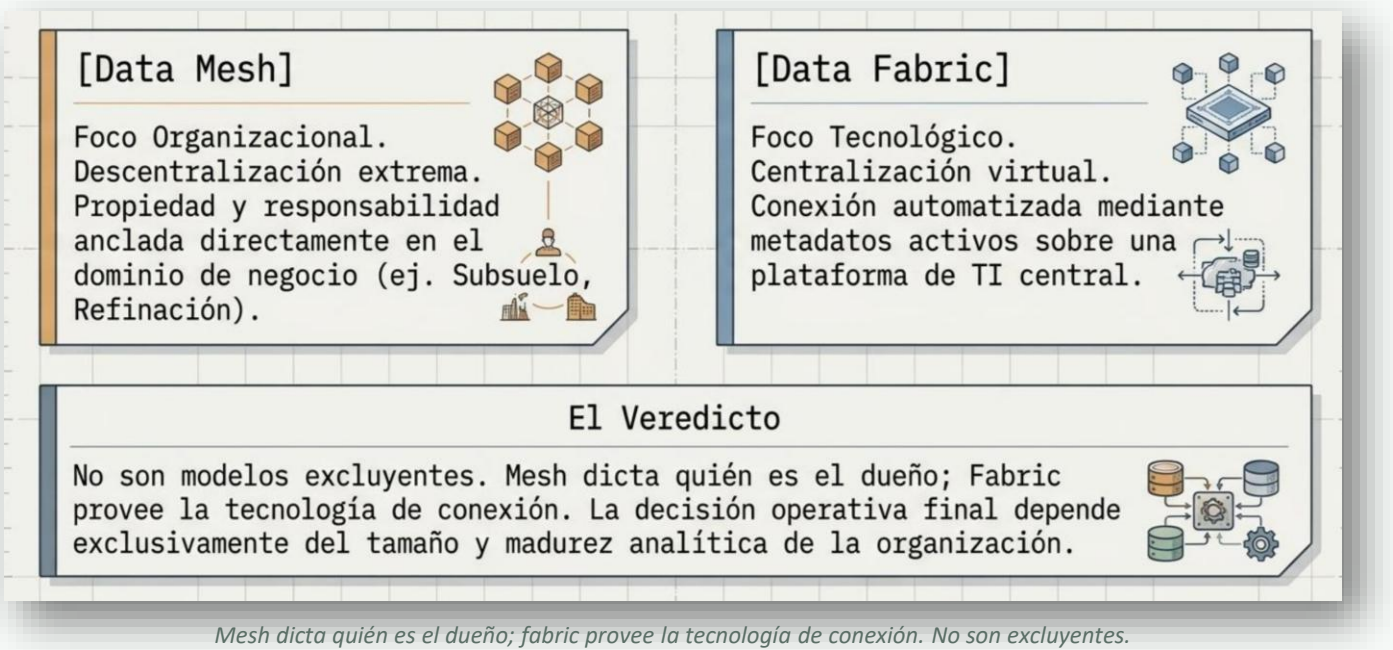
Federación

Es lo que el data fabric automatiza con metadatos activos, sin mover el dato

Y el reverse ETL cierra el ciclo: el dato refinado del lakehouse vuelve a la operación. Es propagación en sentido inverso, y es lo que convierte un data product en algo que cambia decisiones.

9 Data mesh y data fabric: organización contra tecnología

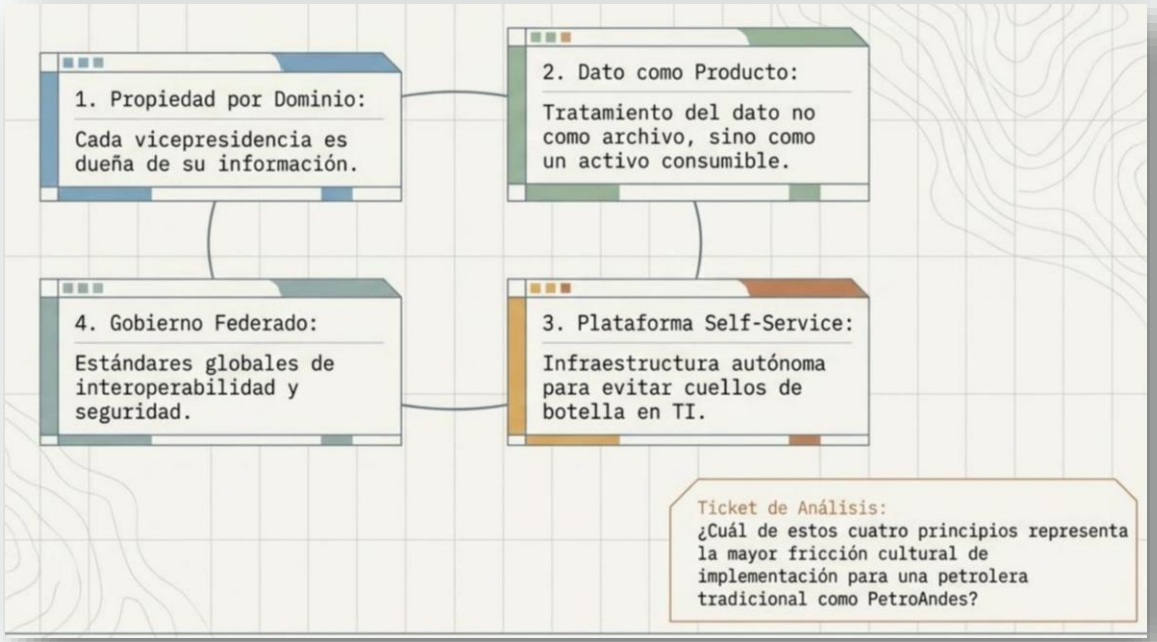
Bloque 3 · la pregunta que resuelve cada uno es distinta



Mesh dicta quién es el dueño; fabric provee la tecnología de conexión. No son excluyentes.

9 Los cuatro principios del data mesh

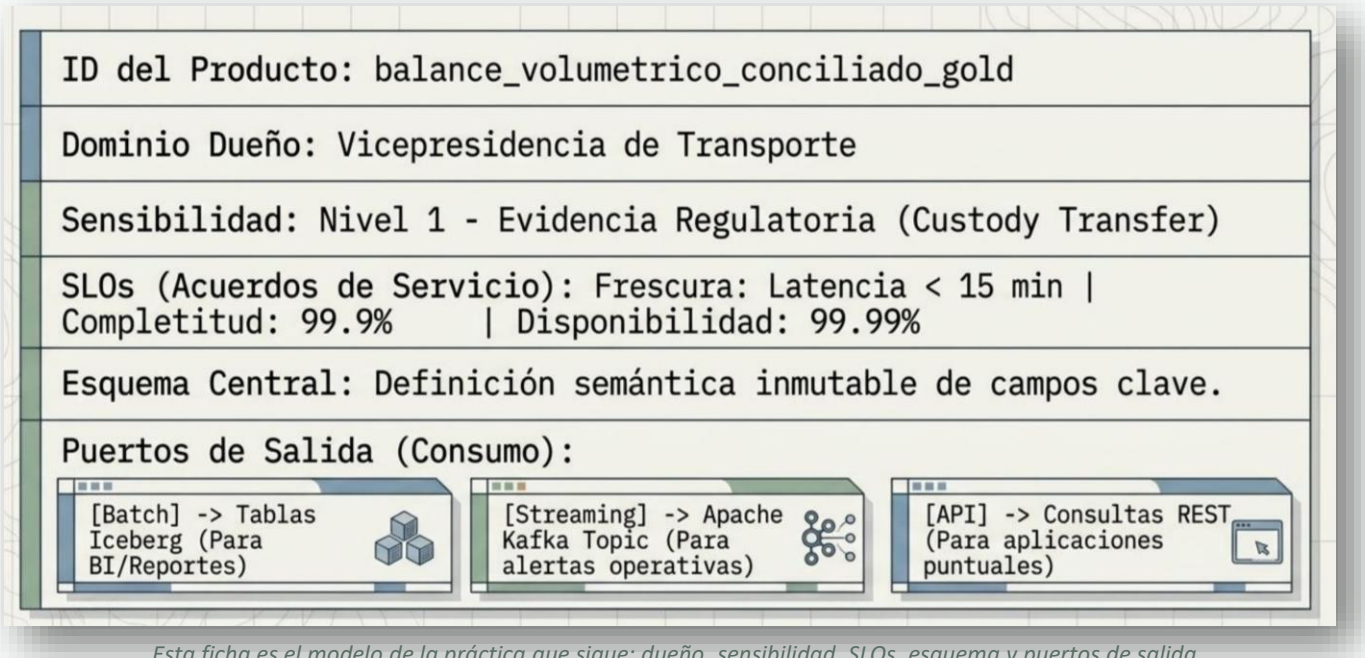
Bloque 3 · descentralizar sin perder interoperabilidad



El primero es el mismo criterio de propiedad del dato que aplicaron en la práctica de la sesión 7.

9 Anatomía del contrato de datos

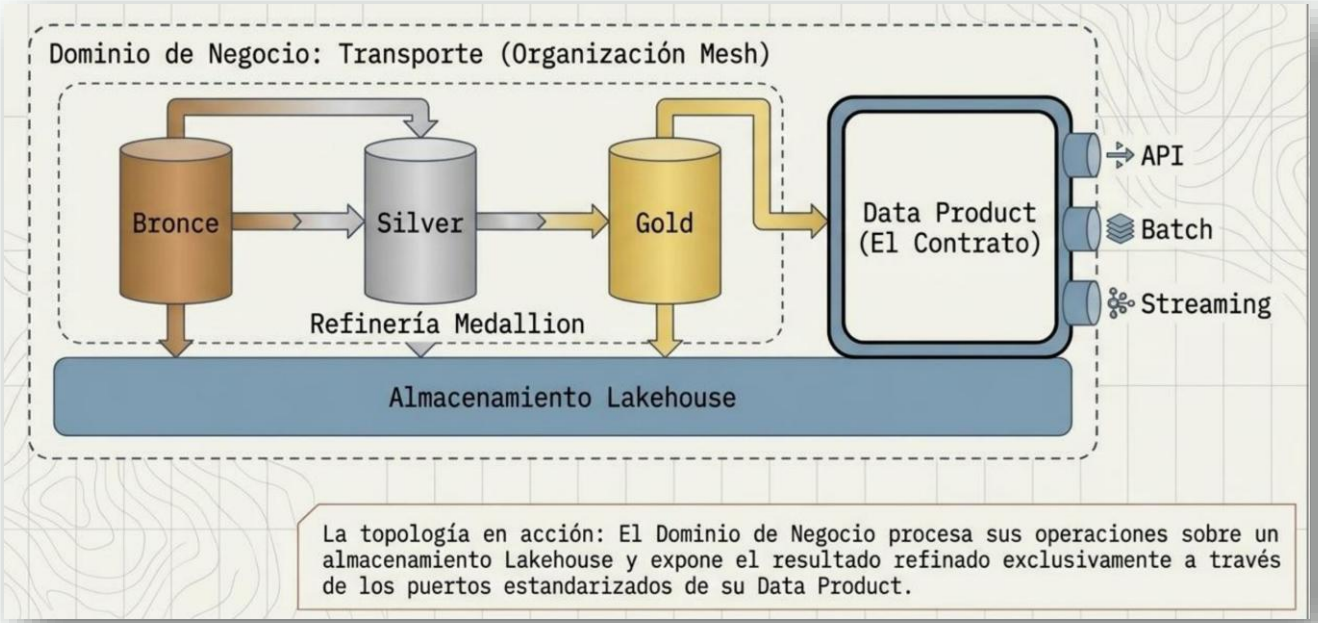
Bloque 3 · un data product es un contrato, no un archivo



Esta ficha es el modelo de la práctica que sigue: dueño, sensibilidad, SLOs, esquema y puertos de salida.

9 Síntesis: el ecosistema operativo unificado

Bloque 3 · cómo se ven juntas todas las piezas de la sesión



El dominio procesa sobre el lakehouse y expone el resultado solo a través de los puertos de su data product.

9 Arquitectura de referencia de datos y analítica — PetroAndes

Capacidades, no productos: cada bloque se puede implementar con tecnologías distintas sin cambiar la arquitectura

1 FUENTES OT

- SCADA y DCS
- Historiador PI
- Custody transfer
- LIMS
- EAM / mantenimiento

FUENTES IT

- SAP IS-Oil
- Sistema comercial
- ETRM
- ANH · MinMinas
- Corpus documental

DMZ INDUSTRIAL · PURDUE 3.5

2 Integración de datos

- **Propagación** — CDC · eventos · streaming
- **Consolidación** — ELT y cargue por lotes
- **Federación** — virtualización de consulta
- **Ingesta documental** — manuales y procedimientos
- **Contratos de datos** — esquema, versión y SLO

3 Repositorio de información

- **Lakehouse** — bronce · plata · oro
- **Formatos abiertos** — ACID y versionado
- **Almacén vectorial** — embeddings del corpus
- **Series de tiempo** — telemetría y sensores

4 Procesamiento

- Consulta SQL
- En memoria
- Streaming
- Búsqueda vectorial

5 Ciencia de datos y MLOps

- Preparación
- Entrenamiento
- Evaluación
- Despliegue
- Deriva y calidad
- Registro de modelos

6 IA generativa y agéntica

- **RAG** — sobre el corpus técnico
- **Agentes y herramientas** — protocolo MCP
- **AI gateway** — costo, política y auditoría
- **Guardrails y evaluación** — citas y vigencia del dato

7 Inteligencia de negocios

- Reporte regulatorio
- Tableros de mando
- Autoservicio
- Lenguaje natural
- Móvil y contextual

8 Activación y consumo

- **APIs analíticas** — consulta puntual
- **Reverse ETL** — de vuelta a la operación
- **Eventos salientes** — alertas y disparadores
- **Copilotos de operación** — con aprobación humana
- **Plataforma BI** — y apps de terceros

9 Gobierno federado

data mesh: dominio dueño y dato como producto

Catálogo, linaje y clasificación

Seguridad e identidad, también de agentes

FinOps: costo por dominio y por token

El data fabric es la capa de metadatos activos que conecta los bloques 2, 3 y 7; el data mesh es quién responde por cada data product.

9 Práctica — Ficha del data product, en papel

Bloque 4 · 35 min · en grupos · el computador solo para consultar el caso

COMPLETE A MANO LA FICHA DE UN DATA PRODUCT

- **Identificador y dominio dueño** — qué vicepresidencia responde por él
- **Clasificación de sensibilidad** — ¿es evidencia regulatoria?
- **SLOs** — frescura, completitud y disponibilidad, con cifras
- **Esquema central** — los campos cuya semántica no puede cambiar
- **Puertos de salida** — batch, streaming o API, y para qué consumidor cada uno
- **Política de evolución** — qué cambio obliga a avisar y a quién

ELIJA UNO DE ESTOS

- Balance volumétrico conciliado
- Inventario de emisiones GEI por activo
- Producción diaria certificada por pozo
- Ventas y posición frente al FEPC
- Calidades certificadas de producto

Se entrega la hoja al final del bloque. Lo que se califica no es la sofisticación, sino que el dueño, los SLOs y los puertos sean coherentes entre sí y con el uso real del dato.

9 Lanzamiento del Taller 2: fechas y dependencias

Bloque 4 · se publica hoy y se entrega en la sesión 15



El repositorio starter ya está disponible: broker configurado, base de datos simulada y corpus documental.

9 Bibliografía de la sesión

LECTURAS OBLIGATORIAS

- Dehghani, Z. Data Mesh: Delivering Data-Driven Value at Scale. O'Reilly, 2022 — caps. de principios.
- Artículo del curso sobre formatos de tabla abiertos: ACID, versionado y evolución de esquema.
- Kimball, R. y Ross, M. The Data Warehouse Toolkit, 3.ª ed. — modelo dimensional (selección).

OPCIONALES

- Inmon, W. Building the Data Warehouse — arquitectura CIF.
- Comparativo data mesh vs. data fabric (Gartner / ThoughtWorks).
- Apache Iceberg y Delta Lake — documentación de los formatos.
- Kleppmann, M. Designing Data-Intensive Applications — cap. 10.